



Méthodes de régression spatiale : un grand bol d'R

Philippe Apparicio

Jean Dubé

Jérémy Gelb

Joan Carles Martori

2025-01-24

Table des matières

Préface	1
Un manuel sous la forme d'une ressource éducative libre	2
Comment lire ce manuel?	4
Comment utiliser les données du livre pour reproduire les exemples?	4
Liste des <i>packages</i> utilisés	5
Bref historique sur les modèles de régressions spatiales en économie et en géographie	5
Structure du livre	6
Remerciements	7
À propos des auteurs	8
Partie 1. Notions de base	9
1 Notions de base	10
1.1 Description des jeux de données utilisés dans le manuel	10
1.1.1 Jeu de données sur l'agglomération de Lyon	10
1.1.2 Jeu de données sur Barcelone	13
1.1.3 Jeu de données sur la densité pour six villes espagnoles	13
1.1.4 Jeu de données sur la densité pour six régions métropolitaines espagnoles	13
1.2 Conceptualisation de l'espace : matrices des pondérations spatiales	13
1.2.1 Matrices de contiguïté	13
1.2.2 Matrices de proximité	13
1.2.3 Standardisation des matrices de pondération spatiale en ligne	13
1.2.4 Mise en œuvre dans R	13
1.3 Notion de variable spatialement décalée	13
1.4 Notion d'autocorrélation spatiale	13
1.4.1 Autocorrélation spatiale globale	13
1.4.1.1 Statistique du I de Moran	13
1.4.1.2 Statistiques de comptage de jointure	13
1.4.2 Autocorrélation spatiale locale	13
1.4.2.1 Statistiques locales de Getis et Ord	13
1.4.2.2 Typologie basée sur le diagramme de Moran	13
1.4.2.3 Version locale des statistiques de comptage de jointure	13
1.5 Retour sur la régression linéaire multiple	13
1.6 Notion de dépendance spatiale et d'hétérogénéité spatiale et de non-stationnarité spatiale	16
1.7 Pourquoi recourir à des régressions spatiales?	16

Partie 2. Économétrie spatiale	17
2 Modèles d'économétrie spatiale	18
2.1 Pourquoi recourir à des modèles économétriques spatiaux?	19
2.2 Les différents modèles spatiaux autorégressifs	19
2.2.1 Modèle SLX : prise en compte des caractéristiques des voisins	20
2.2.2 Description du Modèle SLX	20
2.2.3 Mise en œuvre dans R	21
2.2.4 Modèle SAR : autocorrélation spatiale sur la variable dépendante	27
2.2.5 Modèle SEM : autocorrélation spatiale sur le terme d'erreur	32
2.2.6 Modèle SDM : autocorrélation spatiale sur la variable dépendante et les variables indépendantes	33
2.2.7 Modèle SDEM : autocorrélation spatiale sur les variables indépendantes et sur le terme d'erreur	36
2.3 Quel modèle choisir?	39
2.3.1 Tests du multiplicateur de Lagrange sur le modèle MCO	39
2.3.2 Comparaison des modèles mixtes et non mixtes	40
2.3.3 Mesures AIC et BIC et dépendance spatiale	41
2.4 Quiz de révision	44
2.5 Exercices de révision	44
3 Modèles d'économétrie spatiale par panel	46
3.1 Bref retour sur les modèles en panel	47
3.2 Formulation des différents modèles spatiaux par panel	47
3.2.1 Description des différents modèles	47
3.2.2 Modèle SLPDM : autocorrélation sur la variable dépendante	47
3.2.3 Modèle SEPDM : autocorrélation sur le terme d'erreur	47
3.2.4 Modèle SEPDM : autocorrélation sur la variable dépendante et les variables indépendantes	47
3.3 Sélection du modèle spatial par panel le plus approprié	47
3.4 Mise en œuvre dans R	47
3.5 Quiz de révision	47
3.6 Exercices de révision	47
Partie 3. Régressions géographiquement pondérées	49
4 Régressions géographiquement pondérées classiques	50
4.1 Principe de base	51
4.1.1 Pourquoi recourir à une régression géographiquement pondérée?	51
4.1.2 Formulation de la GWR	51
4.1.3 Exemple applicatif de la GWR	53
4.1.3.1 Résultats du modèle global	53
4.1.3.2 Résultats du modèle GWR	53
4.2 Mise en œuvre et analyse dans R	54
4.2.1 GWR avec le <i>package</i> <code>spgwr</code>	56
4.2.1.1 Définition de la taille de la zone d'influence	56
4.2.1.2 Réalisation de la GWR	58
4.2.1.3 Comparaison des modèles MCO et GWR	59
4.2.1.4 Cartographie des résultats du modèle GWR	63

4.2.2	GWR avec le <i>package</i> <code>GWmodel</code>	73
4.2.2.1	Définition de la taille de la zone d'influence	73
4.2.2.2	Réalisation de la GWR	76
4.2.2.3	Cartographie des résultats du modèle GWR	78
4.3	GWR classiques pour d'autres distributions	81
4.4	Limites et critiques des GWR	81
4.5	Quiz de révision	84
4.6	Exercices de révision	84
5	Extensions de la régression géographiquement pondérée	86
5.1	Régression géographiquement pondérée mixte	88
5.1.1	Principe de base de la GWR mixte	88
5.1.1.1	Pourquoi recourir à une GWR mixte	88
5.1.1.2	Formulation de la GWR mixte	88
5.1.2	Mise en oeuvre de la GWR mixte dans R	88
5.2	Régression géographiquement pondérée multiéchelle	88
5.2.1	Principe de base de la MGWR	88
5.2.1.1	Pourquoi recourir à une GWR mixte	88
5.2.1.2	Formulation de la GWR mixte	88
5.2.2	Mise en oeuvre de la MGWR dans R	88
5.3	Régression géographiquement pondérée mixte avec des variables spatialement décalée	88
5.3.1	Principe de base de la MGWR-SAR	88
5.3.1.1	Pourquoi recourir à une MGWR-SAR	88
5.3.1.2	Formulation de la MGWR-SAR	88
5.3.2	Mise en oeuvre de la MGWR-SAR dans R	88
5.4	Quiz de révision	88
5.5	Exercices de révision	88
	 Partie 4. Autres approches de modélisations spatiales	 90
6	Modèles généralisés additifs	91
6.1	Modèles généralisés additifs (GAM) avec une <i>spline</i> bivariée sur les coordonnées géographiques	91
6.1.1	Principe de base d'un GAM intégrant l'espace	92
6.1.1.1	Formulation d'un modèle GAM avec une <i>spline</i> bivariée sur les coordonnées géographiques	92
6.1.1.2	Pourquoi recourir à un modèle GAM avec une <i>spline</i> bivariée sur les coordonnées géographiques	92
6.1.2	Mise en oeuvre et analyse dans R	92
6.1.2.1	Réalisation du modèle GAM	92
6.1.2.2	Visualisation de l'effet de l'espace	95
6.1.2.3	Dépendance spatiale du modèle GAM	98
6.2	GAM avec un lissage par champ aléatoire de Markov	99
6.2.1	Principe de base d'un avec un champ aléatoire de Markov	99
6.2.2	Mise en oeuvre et analyse dans R	99
6.3	Quiz de révision	101
6.4	Exercices de révision	101

7	Modèles avec des vecteurs propres spatiaux	102
	Partie 7. Exercices et bibliographie	103
8	Correction des exercices	104
8.1	Exercices du chapitre 1	104
8.1.1	Exercice 1	104
8.1.2	Exercice 2	104
8.1.3	Exercice 3	104
8.2	Exercices du chapitre 2	104
8.2.1	Exercice 1	104
8.2.2	Exercice 2	104
8.2.3	Exercice 3	104
8.3	Exercices du chapitre 3	104
8.3.1	Exercice 1	104
8.3.2	Exercice 2	104
8.3.3	Exercice 3	104
8.4	Exercices du chapitre 4	104
8.4.1	Exercice 1	104
8.4.2	Exercice 2	105
8.4.3	Exercice 3	106
8.5	Exercices du chapitre 5	108
8.5.1	Exercice 1	108
8.5.2	Exercice 2	108
8.5.3	Exercice 3	108
	Bibliographie	109

Liste des figures

1	Licence Creative Commons du livre	3
2	Téléchargement de l'intégralité du livre	5
1.1	Cartographie des variables du jeu de données LyonIris	11
2.1	Cartographie des résidus du modèle SLX	26
2.2	Cartographie des résidus du modèle SAR	31
2.3	Comparaison des différents modèles	43
4.1	Fonctions kernel pour définir la matrice de pondération $W(i)$	52
4.2	Cartographie des valeurs de t : moins de 15 ans (%)	55
4.3	Variables indépendantes significatives du modèle GWR	56
4.4	Cartographie des résidus des modèles MCO et GWR	63
4.5	Cartographie des R carrés locaux de la GWR	66
4.6	Cartographie des coefficients de régression de la GWR	68
4.7	Cartographie des valeurs de t de la GWR	70
4.8	Nombre de variables significatives aux seuils de 5% et 1%	71
4.9	Variable indépendante la plus significative au seuil de 5 %	72
4.10	Exemple de cartographie avec les résultats de la GWR obtenus avec le <i>package</i> <code>GWmodel</code>	80
4.11	Corrélation de Pearson entre les coefficients de régression locaux de la GWR	83
6.1	Visualisation des prédictions dans l'espace avec la fonction <code>vis.gam</code>	96
6.2	Visualisation de l'effet de la localisation centrée sur zéro	98

Listes des tableaux

1.1	Statistiques descriptives du jeu de données LyonIris	12
4.1	Résultats du modèle global (régression linéaire multiple)	53
4.2	Analyse de variance entre les modèles global et GWR	54

Préface

Résumé : Ce livre vise à décrire une panoplie de méthodes de régression spatiale avec le logiciel ouvert R. La philosophie de ce livre est de donner toutes les clefs de compréhension et de mise en œuvre des méthodes abordées dans R. La présentation des méthodes est basée sur une approche compréhensive et intuitive plutôt que mathématique, sans pour autant négliger la rigueur statistique.

Remerciements : Ce manuel a été réalisé avec le soutien de la fabriqueREL. Fondée en 2019, la fabriqueREL est portée par divers établissements d'enseignement supérieur du Québec et agit en collaboration avec les services de soutien pédagogique et les bibliothèques. Son but est de faire des ressources éducatives libres (REL) le matériel privilégié en enseignement supérieur au Québec.

Maquette de la page couverture et identité graphique du livre : Andrés Henao Florez.

Mise en page : Philippe Apparicio et Marie-Hélène Gadbois Del Carpio.

Révision linguistique : Denise Latreille.

© Philippe Apparicio, Jean Dubé, Jérémy Gelb et Joan Carles Martori.

Pour citer cet ouvrage : Apparicio P., J. Dubé, J. Gelb et J. C. Martori (2024). *Méthodes de régression spatiale : un grand bol d'R*. Université Laval et Université de Sherbrooke. fabriqueREL. Licence CC BY-SA.



Sauf indications contraires, le contenu de ce manuel électronique est disponible en vertu des termes de la [Licence Creative Commons Attribution - Partage dans les mêmes conditions 4.0 International](#).

Vous êtes autorisé-e à :

Partager – copier, distribuer et communiquer le matériel par tous moyens et sous tous formats.

Adapter – remixer, transformer et créer à partir du matériel pour toute utilisation, y compris commerciale.

Selon les conditions suivantes :

Paternité – Vous devez citer le nom des auteurs originaux.

Mêmes conditions – Si vous remixez, transformez, ou créez à partir du matériel composant l'Œuvre originale, vous devez diffuser l'Œuvre modifiée avec la même licence.



Université de
Sherbrooke



fabriqueREL
RESSOURCES ÉDUCATIVES LIBRES

Un manuel sous la forme d'une ressource éducative libre

Pourquoi un manuel sous licence libre?

Les logiciels libres sont aujourd'hui très répandus. Comparativement aux logiciels propriétaires, l'accès au code source permet à quiconque de l'utiliser, de le modifier, de le dupliquer et de le partager. Le logiciel R, dans lequel sont mises en œuvre les méthodes de régression spatiale décrites dans ce livre, est d'ailleurs à la fois un langage de programmation et un logiciel libre (sous la licence publique générale [GNU GPL2](#)). Par analogie aux logiciels libres, il existe aussi des **ressources éducatives libres (REL)** « dont la licence accorde les permissions désignées par les 5R (**R**etenir – **R**éutiliser – **R**éviser – **R**emixer – **R**edistribuer) et donc permet nécessairement la modification » ([fabriqueREL](#)). La licence de ce livre, CC BY-SA (figure 1), permet donc de :

- **Retenir**, c'est-à-dire télécharger et imprimer gratuitement le livre. Notez qu'il aurait été plutôt surprenant d'écrire un livre payant sur un logiciel libre et donc gratuit. Aussi, nous aurions été très embarrassés que des personnes étudiantes avec des ressources financières limitées doivent payer pour avoir accès au livre, sans pour autant savoir préalablement si le contenu est réellement adapté à leurs besoins.
- **Réutiliser**, c'est-à-dire utiliser la totalité ou une section du livre sans limitation et sans compensation financière. Cela permet ainsi à d'autres personnes enseignantes de l'utiliser dans le cadre d'activités pédagogiques.
- **Réviser**, c'est-à-dire modifier, adapter et traduire le contenu en fonction d'un besoin pédagogique précis puisqu'aucun manuel n'est parfait, tant s'en faut! Le livre a d'ailleurs été écrit intégralement dans R avec [Quarto](#). Quiconque peut ainsi télécharger gratuitement le code source du livre sur [github](#) et le modifier à sa guise (voir l'encadré intitulé *Suggestions d'adaptation du manuel*).
- **Remixer**, c'est-à-dire « combiner la ressource avec d'autres ressources dont la licence le permet aussi pour créer une nouvelle ressource intégrée » ([fabriqueREL](#)).
- **Redistribuer**, c'est-à-dire distribuer, en totalité ou en partie le manuel ou une version révisée sur d'autres canaux que le site Web du livre (par exemple, sur le site Moodle de votre université ou en faire une version imprimée).

La licence de ce livre, CC BY-SA (figure 1), oblige donc à :

- Attribuer la paternité de l'auteur dans vos versions dérivées, ainsi qu'une mention concernant les grandes modifications apportées, en utilisant la formulation suivante : Apparicio Philippe et Jérémy Gelb (2024). *Méthodes d'analyses spatiales : un grand bol d'R*. Université de Sherbrooke. [fabriqueREL](#). Licence CC BY-SA.
- Utiliser la même licence ou une licence similaire à toutes versions dérivées.




Figure 1: Licence Creative Commons du livre

💡 Astuce

Suggestions d'adaptation du manuel

Pour chaque méthode d'analyse spatiale abordée dans le livre, une description détaillée et une mise en œuvre dans R sont disponibles. Par conséquent, plusieurs adaptations du manuel sont possibles :

- Conserver uniquement les chapitres sur les méthodes ciblées dans votre cours.
- En faire une version imprimée et la distribuer aux personnes étudiantes.
- Modifier la description d'une ou de plusieurs méthodes en effectuant les mises à jour directement dans les chapitres.
- Insérer ses propres jeux de données dans les sections intitulées *Mise en œuvre dans R*.
- Modifier les tableaux et figures.
- Ajouter une série d'exercices.
- Modifier les quiz de révision.
- Rédiger un nouveau chapitre.
- Modifier des syntaxes R. Plusieurs *packages* R peuvent être utilisés pour mettre en œuvre telle ou telle méthode. Ces derniers évoluent aussi très vite et de nouveaux *packages* sont proposés fréquemment! Par conséquent, il peut être judicieux de modifier une syntaxe R du livre en fonction de ses habitudes de programmation dans R (utilisation d'autres *packages* que ceux utilisés dans le manuel par exemple) ou de bien mettre à jour une syntaxe à la suite de la parution d'un nouveau *package* plus performant ou intéressant.
- Toute autre adaptation qui permet de répondre au mieux à un besoin pédagogique.

Comment lire ce manuel?

Le livre comprend plusieurs types de blocs de texte qui en facilitent la lecture.

Package

Bloc *packages*

Habituellement localisé au début d'un chapitre, il comprend la liste des *packages* R utilisés pour un chapitre.

Objectif

Bloc objectif

Il comprend une description des objectifs d'un chapitre ou d'une section.

Note

Bloc notes

Il comprend une information secondaire sur une notion, une idée abordée dans une section.

Aller plus loin

Bloc pour aller plus loin

Il comprend des références ou des extensions d'une méthode abordée dans une section.

Astuce

Bloc astuce

Il décrit un élément qui vous facilitera la vie : une propriété statistique, un *package*, une fonction, une syntaxe R.

Attention

Bloc attention

Il comprend une notion ou un élément important à bien maîtriser.

Exercice

Bloc exercice

Il comprend un court exercice de révision à la fin de chaque chapitre.

Comment utiliser les données du livre pour reproduire les exemples?

Ce livre comprend des exemples détaillés et appliqués dans R pour chacune des méthodes abordées. Ces exemples se basent sur des jeux de données structurés et mis à disposition avec le livre. Ils sont disponibles sur le *repo github* dans le sous-dossier *data*, à l'adresse <https://github.com/SerieBoldR/RegressionsSpatiales/tree/main/data>.

Une autre option est de télécharger le *repo* complet du livre directement sur *github* (<https://github.com/SerieBoldR/RegressionsSpatiales>) en cliquant sur le bouton Code, puis le bouton Download ZIP (figure 2). Les données se trouvent

alors dans le sous-dossier nommé **data**.




Figure 2: Téléchargement de l'intégralité du livre

Liste des packages utilisés

Dans ce livre, nous utilisons de nombreux *packages* R que vous pouvez installer avec le code ci-dessous.

```
# Liste des packages
ListePackages <- c("dplyr", "mgwrsar", "plm", "RColorBrewer", "rgeoda", "sf", "spatialreg",
                  "spfilter", "splm", "spdep", "spgwr")
# Packages non installés dans la liste
PackagesNonInstalles <- ListePackages[!(ListePackages %in% installed.packages()[,"Package"])]
# Installation des packages manquants
if(length(new.packages)) install.packages(PackagesNonInstalles)
```

Bref historique sur les modèles de régressions spatiales en économie et en géographie

Depuis une cinquantaine d'années, les économistes et les géographes conçoivent et utilisent largement des méthodes de régression prenant en compte la dimension spatiale : modèles d'économétrie spatiale, régressions géographiquement pondérées, modèles généralisés additifs intégrant une dimension spatiale, modèles avec des vecteurs propres spatiaux, etc.

La notion d'autocorrélation spatiale, étroitement liée aux régressions spatiales, remonte à une période encore plus ancienne. Elle a été introduite notamment par les travaux de Patrick Moran, d'abord en 1948 puis en 1950, suivis par ceux de Robert Geary en 1954 et de Nathan Mantel en 1967 (Moran 1948; Moran 1950; Geary 1954; Mantel 1967). La formalisation des relations spatiales trouve son origine, plus précisément, dans la première loi de la géographie énoncée par Waldo

Tobler en 1970 qui stipule que « tout interagit avec tout, mais les objets proches ont plus de chance de le faire que les objets éloignés [*Everything is related to everything else, but near things are more related than distant things*] » (1970).

En économie, le terme « économétrie spatiale » a été utilisé pour la première fois par Jean Paelinck (1978) à la fin des années 1970. Cependant, il est resté relativement peu exploité jusqu'aux travaux de Luc Anselin, qui publie en 1988 un ouvrage de référence sur le sujet intitulé *Spatial econometrics: methods and models* (Anselin 1988). Il faut néanmoins attendre le développement des outils informatiques avant de voir les applications affluées. Ainsi, au début des années 1990, l'économétrie spatiale a véritablement pris son essor (voir Anselin (2010) pour un historique détaillé). Depuis, ce domaine a gagné en importance, s'établissant presque comme un incontournable pour la prise en compte des effets spatiaux, mais aussi, et surtout, des fameux efforts de débordements (nous y reviendrons).

En géographie, Daniel Griffith est certainement l'un des géographes les plus actifs dans le domaine des régressions spatiales, y allant de plusieurs propositions dans le but de contrôler pour la présence d'autocorrélation spatiale résiduelle. Ses premiers travaux remontent aux années 1980, et il a publié depuis un grand nombre d'ouvrages (notamment, Griffith 1988; Griffith 2003; Griffith, Chun et Li 2019). Puis, dans les années 1990, trois géographes – Stewart Fotheringham, Chris Brunsdon et Martin Charlton – ont introduit la régression géographiquement pondérée, une méthode permettant d'analyser localement les relations entre la variable dépendante et les variables indépendantes d'un modèle de régression (Stewart Fotheringham, Charlton et Brunsdon 1996; Brunsdon, Fotheringham et Charlton 1996; Brunsdon, Fotheringham et Charlton 1998). En 2003, la parution de leur ouvrage intitulé *Geographically weighted regression: the analysis of spatially varying relationships* (Fotheringham, Brunsdon et Charlton 2003) a largement contribué à la popularisation de cette méthode.

Structure du livre

Depuis une cinquantaine d'années, les économètres, les épidémiologistes et les géographes conçoivent et utilisent largement des méthodes de régression prenant en compte la dimension spatiale, dont les principales sont présentées dans ce manuel. Ce dernier est structuré en cinq grandes sections.

Partie 1. Notions de base. Dans cette première partie, nous présentons les jeux de données utilisées pour mettre en œuvre les différentes méthodes de régression spatiale présentées dans le livre (chapitre 1). Nous discutons aussi de plusieurs notions fondamentales et méthodes qu'il importe de bien maîtriser avant d'aborder les chapitres suivants consacrés aux méthodes de régression spatiale, notamment : l'autocorrélation spatiale (globale et locale), la notion de variable spatialement décalée et la régression linéaire multiple. Nous concluons ce chapitre en exposant les raisons qui justifient l'utilisation de différentes formes de régressions spatiales pour modéliser des données spatiales ou spatiotemporelles.

Partie 2. Modèles d'économétrie spatiale. Cette seconde partie est consacrée aux modèles d'économétrie spatiale qui vise à modéliser la **dépendance spatiale**. Dans le chapitre 2, nous décrivons ainsi les principaux modèles spatiaux autorégressifs qui permettent d'introduire l'autocorrélation spatiale sur les variables indépendantes (modèle SLX), la variable dépendante (SAR), sur le terme d'erreur (SEM), à la fois sur la variable dépendante et les variables indépendantes (SDM) ou à la fois sur les variables indépendantes et sur le terme d'erreur (SDEM). Dans le chapitre 3, nous abordons une extension des modèles autorégressifs, soit les modèles spatiaux par panel qui permettent de modéliser des données spatiales longitudinales.

Partie 3. Régressions géographiquement pondérées. Dans cette partie, nous abordons les régressions géographiquement pondérées (GWR) qui permettent de modéliser l'**hétérogénéité spatiale**, soit l'instabilité des relations entre la variable dépendante et celles indépendantes. Premièrement, nous décrivons les formes dites classiques de la GWR qui s'appliquent à des variables dépendantes continues, dichotomiques (logistique) et de comptage (Poisson) (chapitre 4).

Deuxièmement, nous abordons des extensions des la GWR, particulièrement la GWR mixte, la GWR multiéchelle et les GWR mixtes avec des variables spatialement décalées (MGWR-SAR) (chapitre 5).

Partie 4. Autres modèles de régressions spatiales. Cette quatrième et dernière partie comprend deux chapitres. Le chapitre 6 est consacré aux modèles généralisés additifs qui permettent d'introduire l'espace deux manières différentes : les modèles GAM avec une *spline* bivariée avec les coordonnées géographiques (x, y) pour capturer les variations continues dans l'espace; les modèles GAM avec un lissage par champ aléatoire de Markov (*random markov field* – RMF) pour modéliser la dépendance spatiale entre les unités spatiales voisines. Dans le chapitre 7, nous nous abordons les modèles linéaires généralisés avec des vecteurs spatiaux proposés par Daniel Griffith (2003; Griffith, Chun et Li 2019).

Remerciements

De nombreuses personnes ont contribué à l'élaboration de ce manuel.

Ce projet a bénéficié du soutien pédagogique et financier de la *fabriqueREL* (ressources éducatives libres). Les différentes rencontres avec le comité de suivi nous ont permis de comprendre l'univers des ressources éducatives libres (REL) et notamment leurs *fameux 5R* (Retenir — Réutiliser — Réviser — Remixer — Redistribuer), de mieux définir le besoin pédagogique visé par ce manuel, d'identifier des ressources pédagogiques et des outils pertinents pour son élaboration. Ainsi, nous remercions chaleureusement les membres de la *fabriqueREL* pour leur soutien inconditionnel :

- Marianne Demers-Desmarais, bibliothécaire, Université Laval.
- Julie-Christine Gagné, conseillère en pédagogie universitaire, Université Laval.
- Claude Potvin, conseiller pédagogique à la fabriqueREL, Université Laval.
- Nadia Villeuneuve, bibliothécaire, Université Laval.

À MODIFIER PLUS TARD. Nous remercions aussi les membres du comité de révision pour leurs commentaires et suggestions très constructifs. Ce comité est composé de quatre personnes étudiantes du *Département de géomatique appliquée* de l'*Université de Sherbrooke* :

- Gaël Machemin et Loek Pascaud, étudiants à la *maîtrise en géomatique appliquée et télédétection (type recherche)*.
- Rosemarie Légaré, étudiante à la *maîtrise en géomatique appliquée et télédétection*.
- Marie-Hélène Gadbois Del Carpio, étudiante à la *maîtrise en géomatique appliquée et télédétection* a participé activement à la mise en page du manuel; elle est désormais une grande spécialiste des feuilles de style en cascade (CSS) et de Quarto.

Finalement, nous remercions Denise Latreille, réviseuse linguistique et chargée de cours à l'Université Sherbrooke, pour la révision du manuel.

À propos des auteurs

Philippe Apparicio est professeur titulaire au Département de géomatique appliquée de l'Université de Sherbrooke. Il y enseigne aux programmes de 1^{er} et 2^e cycles de géomatique les cours *Transport et mobilité durable*, *Modélisation et analyse spatiale* et *Géomatique appliquée à la gestion urbaine*. Géographe de formation, ses intérêts de recherche incluent la justice et l'équité environnementale, la mobilité durable, les pollutions atmosphérique et sonore, et le vélo en ville. Il a publié une centaine d'articles scientifiques dans différents domaines des études urbaines et de la géographie mobilisant la géomatique et l'analyse spatiale.

Jean Dubé est professeur titulaire à l'École Supérieure d'aménagement du territoire et de développement régional (ÉSAD) de l'Université Laval. Économiste de formation, ses intérêts de recherche portent notamment sur l'évaluation d'impact des politiques publiques liées à l'aménagement et au développement. Ses recherches portent sur la mesure des externalités urbaines par le marché immobilier, les décisions de localisation des entreprises et des ménages et les déterminants de la croissance urbaine et régionale. Il est aussi rédacteur de la *Revue canadienne des sciences régionales* (RCSR).

Jérémy Gelb a obtenu un doctorat en études urbaines à l'INRS en 2022 (*L'exposition des cyclistes aux pollutions atmosphérique et sonore en milieu urbain : comparaison empirique de plusieurs villes à travers le monde*), sous la supervision de Philippe Apparicio. Il utilise quotidiennement les systèmes d'information géographique (SIG) et des méthodes d'analyses spatiales. Il est tombé dans la marmite de l'*open source* avec le triptyque QGIS, R et Python au début de sa maîtrise. Il a développé deux *packages* : *geomeans* et *spNetwork*, permettant respectivement d'effectuer des analyses de classification floue non supervisée pondérée spatialement et des estimations de densité par kernel sur réseau. Il travaille actuellement comme conseiller en science des données à l'Autorité régionale de transport métropolitain qui gère la planification du transport collectif dans la région de Montréal. Ces travaux portent sur la qualité des milieux urbains, l'accessibilité spatiale, le transport, l'équité environnementale, les SIG et l'analyse spatiale.

Joan Carles Martori est professeur d'économie appliquée au département d'économie et de commerce de l'Université de Vic - Université centrale de la Catalogne (Barcelone, Espagne). Il enseigne les statistiques appliquées et l'économétrie dans des cours de premier et de deuxième cycle. Il est le chercheur principal du groupe *Data Analysis and Modelling*. Économiste de formation, ses recherches portent sur la ségrégation résidentielle, les inégalités et l'équité environnementale à l'aide des statistiques spatiales et de techniques économétriques. Il a contribué au développement du *package* R *AQuadtree* sur la confidentialité des données spatiales ponctuelles. En tant que statisticien appliqué, il collabore avec d'autres disciplines telles que l'éducation et la santé.

Partie 1. Notions de base

1 Notions de base

Dans ce chapitre, nous décrivons... A compléter.

Package

Liste des *packages* utilisés dans ce chapitre

- Pour importer et manipuler des fichiers géographiques :
 - `sf` pour importer et manipuler des données vectorielles.
- Pour cartographier des données :
 - `ggplot2` est un *package* pour construire des graphiques qui peut être aussi utilisé pour visualiser des données spatiales.
 - `tmap` pour construire des cartes thématiques.
 - `RColorBrewer` pour construire une palette de couleur.
 - `ggpurb` pour combiner des graphiques et des cartes.

1.1 Description des jeux de données utilisés dans le manuel

Plusieurs jeux de données sont utilisés dans ce livre et sont déjà structurés et disponibles au format `.Rdata`.

Attention

Manipulation, structuration et cartographie de données spatiales

Ce livre n'a pas pour objectif de traiter la phase préparatoire consistant à structurer les données spatiales dans R avant l'application de modèles de régression spatiale. Nous partons du principe que les lectrices et lecteurs maîtrisent déjà l'utilisation des *packages* `sf` et `tmap` pour manipuler, structurer et cartographier des données spatiales. Si ce n'est pas le cas, nous vous encourageons à consulter le chapitre intitulé *Manipulation des données spatiales dans R* (Apparicio et Gelb 2024).

1.1.1 Jeu de données sur l'agglomération de Lyon

Premièrement, nous utiliserons le jeu de données spatiales `LyonIris` du *package* `geocmeans`. Ce jeu de données spatiales pour l'agglomération lyonnaise (France) comprend dix variables, dont quatre environnementales (EN) et six socioéconomiques (SE), pour les îlots regroupés pour l'information statistique (IRIS) de l'agglomération lyonnaise (tableau 1.1 et figure 1.1).




Figure 1.1: Cartographie des variables du jeu de données LyonIris

Tableau 1.1: Statistiques descriptives du jeu de données LyonIris

Nom	Intitulé	Type	Moy.	E.-T.	Min.	Max.
Lden	Bruit routier (Lden dB(A))	EN	55,6	4,9	33,9	71,7
NO2	Dioxyde d'azote (ug/m ³)	EN	28,7	7,9	12,0	60,2
PM25	Particules fines (PM _{2,5})	EN	16,8	2,1	11,3	21,9
VegHautPrt	Canopée (%)	EN	18,7	10,1	1,7	53,8
Pct0_14	Moins de 15 ans (%)	SE	18,5	5,7	0,0	54,0
Pct_65	65 ans et plus (%)	SE	16,2	5,9	0,0	45,1
Pct_Img	Immigrants (%)	SE	14,5	9,1	0,0	59,8
TxChom1564	Taux de chômage	SE	14,8	8,1	0,0	98,8
Pct_brevet	Personnes à faible scolarité (%)	SE	23,5	12,6	0,0	100,0
NivVieMed	Médiane du niveau de vie (milliers d'euros)	SE	21,8	4,9	11,3	38,7

1.1.2 Jeu de données sur Barcelone

1.1.3 Jeu de données sur la densité pour six villes espagnoles

1.1.4 Jeu de données sur la densité pour six régions métropolitaines espagnoles

1.2 Conceptualisation de l'espace : matrices des pondérations spatiales

1.2.1 Matrices de contiguïté

1.2.2 Matrices de proximité

1.2.3 Standardisation des matrices de pondération spatiale en ligne

1.2.4 Mise en œuvre dans R

1.3 Notion de variable spatialement décalée

1.4 Notion d'autocorrélation spatiale

1.4.1 Autocorrélation spatiale globale

1.4.1.1 Statistique du I de Moran

1.4.1.2 Statistiques de comptage de jointure

1.4.2 Autocorrélation spatiale locale

1.4.2.1 Statistiques locales de Getis et Ord

1.4.2.2 Typologie basée sur le diagramme de Moran

1.4.2.3 Version locale des statistiques de comptage de jointure

1.5 Retour sur la régression linéaire multiple

À titre de rappel, la régression linéaire multiple permet d'exprimer une variable d'intérêt, habituellement notée par le terme variable dépendante (y) en fonction de plusieurs variables que l'on pense liées, théoriquement, à la variable d'intérêt. Celles-ci sont habituellement désignées comme des variables explicatives ou indépendantes (notés x_k).

L'équation de régression s'écrit alors :

$$y_i = \alpha + \beta_1 x_{1i} + \beta_2 x_{2i} + \cdots + \beta_K x_{Ki} + \varepsilon_i \quad (1.1)$$

Où :

- y_i , est la valeur de la variable dépendante y pour l'observation spatiale i .
- x_{ki} , est la valeur de la variable indépendante x_k pour l'observation spatiale i .
- α , est le paramètre d'ordonnée à l'origine, ou encore la constante. Elle représente la valeur moyenne de la variable dépendante lorsque l'ensemble des variables indépendantes (ou explicatives) sont nulles.
- $k = 1, 2, \dots, K$ est le nombre de variables indépendantes.
- β_1 à β_K , sont les coefficients de régression liés à chacune des variables indépendantes.
- ε_i , est le terme d'erreur, soit la partie de la valeur de la variable dépendante qui n'est pas expliquée par le modèle de régression. Le terme d'erreur est habituellement supposé de moyenne nulle, de variance homogène et indépendant.

À noter que le terme d'erreur est, par définition, inobservable. En revanche, il est possible d'approximer cette valeur en calculant le résidu, $\hat{\varepsilon}_i$, parfois aussi noté $\hat{e}_i$ (équations 1.2 et 1.3).

$$\hat{\varepsilon}_i = \hat{y}_i - y_i \quad (1.2)$$

$$\hat{\varepsilon}_i = y_i - \left[\hat{\alpha} + \hat{\beta}_1 x_{1i} + \hat{\beta}_2 x_{2i} + \dots + \hat{\beta}_K x_{Ki} \right] \quad (1.3)$$

Il existe plusieurs manières d'exprimer cette relation sous forme plus compacte. L'une de celle-ci consiste à introduire le terme de sommation dans l'équation :

$$y_i = \alpha + \sum_{k=1}^K \beta_k x_{ki} + \varepsilon_i \quad (1.4)$$

Une autre approche, plus pratique et compacte, consiste à utiliser la notation matricielle :

$$y = \iota\alpha + X\beta + \varepsilon \quad (1.5)$$

Où :

- y , est un vecteur de dimension $(N \times 1)$ où N est le nombre total d'observations mobilisées dans l'analyse, avec $i = 1, 2, \dots, N$.
- ι est un vecteur de dimension $(N \times 1)$ comportant uniquement des valeurs de 1.
- X , une matrice de dimension $(N \times K)$ renfermant l'ensemble des K vecteurs de variables explicatives en plus d'une colonne de 1, dans la première colonne de la matrice, pour la constante, d'où $(K + 1)$.
- α est un scalaire identifiant l'ordonnée à l'origine.
- β , est un vecteur de dimension $(K + 1)$ qui renferme l'ensemble des coefficients de régression, pour les K variables indépendantes et la constante.
- ε , un vecteur de dimension $(N \times 1)$ des termes d'erreurs.

De manière plus explicite, les différents vecteurs et matrices prennent les formes suivantes :

$$y = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_i \\ \vdots \\ y_N \end{bmatrix} \quad (1.6)$$

$$\iota = \begin{bmatrix} 1 \\ 1 \\ \vdots \\ 1 \\ \vdots \\ 1 \end{bmatrix} \quad (1.7)$$

$$X = \begin{bmatrix} x_{11} & x_{12} & x_{13} & \cdots & x_{1k} & \cdots & x_{1K} \\ x_{21} & x_{22} & x_{23} & \cdots & x_{2k} & \cdots & x_{2K} \\ \vdots & \vdots & \vdots & \ddots & \vdots & \ddots & \vdots \\ x_{i1} & x_{i2} & x_{i3} & \cdots & x_{ik} & \cdots & x_{iK} \\ \vdots & \vdots & \vdots & \ddots & \vdots & \ddots & \vdots \\ x_{N1} & x_{N2} & x_{N3} & \cdots & x_{Nk} & \cdots & x_{NK} \end{bmatrix} \quad (1.8)$$

$$\beta = \begin{bmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_k \\ \vdots \\ \beta_K \end{bmatrix} \quad (1.9)$$

Les modèles de régression linéaire sont largement mobilisés lorsqu'on s'intéresse à l'effet d'une variable spécifique sur le comportement de la variable d'intérêt. Le terme « effet marginal » est souvent associé aux coefficients estimés, β_k . Les coefficients permettent de simuler l'effet d'une variation d'une variable dépendante, Δx_k , sur la variation du comportement de la variable expliquée, Δy .

En termes plus techniques, les effets marginaux permettent d'exprimer l'effet de la dérivée partielle, c'est-à-dire d'isoler comment la variable d'intérêt bouge lorsqu'une des variables indépendantes bouge :

$$\frac{\partial y}{\partial x_k} = \beta_k \quad (1.10)$$

Ces effets sont habituellement l'essence de l'intérêt des modèles de régression. Par exemple, une variation de deux unités de la variable x_k devrait entraîner une variation dans y de $2\beta_k$ unités. Cette analyse est souvent le centre d'intérêt des modèles de régression, bien que l'interprétation causale ne soit pas nécessairement directe (Dubé et Legros 2014).

 Aller plus loin

Régression linéaire multiple

Afin de bien maîtriser les principes de base et les hypothèses de la régression linéaire multiple, mesurer la qualité d'ajustement du modèle, introduire des variables explicatives particulières (variable qualitative dichotomique ou polytomique, variable d'interaction, etc.), interpréter les résultats d'un modèle de régression la mettre en œuvre dans R, nous vous invitons vivement à lire le [chapitre suivant](#) (Apparicio et Gelb 2022).

1.6 Notion de dépendance spatiale et d'hétérogénéité spatiale et de non-stationnarité spatiale

1.7 Pourquoi recourir à des régressions spatiales?

Partie 2. Économétrie spatiale

2 Modèles d'économétrie spatiale

Dans ce chapitre, nous décrivons uniquement les modèles économétriques spatiaux dont la variable dépendante est continue. Sommairement, ces modèles sont des extensions de la régression linéaire multiple, mais dans lequel une spécification explicite des relations spatiales entre les observations est introduite. Cette spécification vise ultimement à capter des effets spatiaux qui influencent le processus générateur de données (PGD), c'est-à-dire le modèle économétrique que l'on spécifie.

🎯 Objectif

Objectifs d'apprentissage visés dans ce chapitre

À la fin de ce chapitre, vous devriez être en mesure de :

- À modifier.
- À modifier.
- À modifier.
- Analyser les résultats produits par ces différents modèles.
- Mettre en pratique ces modèles spatiaux par panel dans R.

📦 Package

Liste des *packages* utilisés dans ce chapitre

- Pour importer et manipuler des fichiers géographiques :
 - `sf` pour importer et manipuler des données vectorielles.
- Pour construire des cartes et des graphiques :
 - `tmap` est certainement le meilleur *package* pour la cartographie.
 - `ggplot2` pour construire des graphiques.
- Pour construire des modèles spatiaux :
 - `spdep` pour construire des matrices de pondération spatiales et calculer le I de Moran.
 - `spatialreg` pour construire des modèles économétriques spatiaux.

⚠ Attention**Régression linéaire multiple et modèles économétriques spatiaux**

Dans cette section, nous décrivons uniquement les modèles économétriques spatiaux dont la variable dépendante est continue. Sommairement, ces modèles sont des extensions de la régression linéaire multiple, mais dans lequel une spécification explicite des relations spatiales entre les observations est introduite. Cette spécification vise ultimement à capter des effets spatiaux qui influencent le processus générateur de données (PGD), c'est-à-dire le modèle économétrique que l'on spécifie.

Par conséquent, avant de lire cette chapitre, il convient de bien maîtriser la régression linéaire multiple. Une brève récapitulation est proposée dans la section 1.5.

2.1 Pourquoi recourir à des modèles économétriques spatiaux?

Dans un modèle, les résidus (ϵ) sont la différence entre les valeurs observées (y_i) et les valeurs prédites par le modèle ($\hat{y}_i$). Une des hypothèses de la régression linéaire multiple est que les observations doivent être indépendantes les unes des autres (*indépendance du terme d'erreur*). Le non-respect de cette hypothèse produit des résultats biaisés, notamment pour les coefficients de régression. Un simple test de présence d'autocorrélation spatiale entre les résidus (section 1.4.1.1) permet de vérifier si cette hypothèse est respectée.

Le rejet de cette hypothèse d'indépendance rend les coefficients estimés, selon la forme fonctionnelle postulée (ou processus générateur des données – PGD), par le modèle biaisés et/ou biaise le calcul des écarts-types, invalidant ainsi les tests de significativité usuels. La présence d'autocorrélation spatiale entre les résidus est donc un premier test nécessaire pour s'assurer de la qualité des résultats issus du modèle de régression linéaire.

À noter qu'une autocorrélation spatiale entre certaines variables observables, dépendante ou indépendantes, est possible sans pour autant que les résidus soient autocorrélés. Dans ce cas, les relations entre les variables indépendantes permettent de capter l'effet spatial contenu dans la variable dépendante et les résultats d'estimations sont valides si les résidus sont homoscédastiques, c'est-à-dire de variance homogène (autrement, le problème peut facilement être réglé par un simple ajout d'option dans la commande du modèle de régression). Ce n'est donc pas sur les variables observables que le test de détection d'autocorrélation spatiale est important, mais bien sur les résidus du modèle.

Pour être valides, les résultats d'un modèle de régression linéaire construit avec des données spatiales ne devraient pas avoir des résidus spatialement autocorrélés. Si c'est le cas, alors certaines options sont envisageables pour tenter de remédier à la situation. La plus simple étant l'ajout de variables indépendantes spatialement structurées, afin de capter l'autocorrélation résiduelle. Les méthodes plus avancées proposent d'intégrer formellement cette relation spatiale dans le PGD.

2.2 Les différents modèles spatiaux autorégressifs

Selon Jean Dubé et Diègo Legros, quelques raisons expliquent « le choix d'un modèle autorégressif : la présence d'externalités, les effets d'entraînement, l'omission de variables importantes, la présence d'hétérogénéité spatiale des comportements, les effets mixtes » (2014, 120). Les effets mixtes représentent une combinaison d'effets spatiaux. Dans tous les cas, la prise en compte des effets spatiaux passe par la spécification d'une matrice de pondérations spatiales, notée W et de dimension $(N \times N)$.

FAIRE UN TABLEAU Modèles / Motivation / Intégration de l'autocorrélation spatiale SLX / Externalités : influence des caractéristiques d'un voisin sur le comportement d'intérêt d'une observation donnée / Variables indépendantes (WX)

2.2.1 Modèle SLX : prise en compte des caractéristiques des voisins

2.2.2 Description du Modèle SLX

Dans un modèle SLX (*spatial lag of X model*), la dimension spatiale est intégrée par une possible influence des variables indépendantes des observations voisines, ou des caractéristiques des voisins. Cette spécification vise habituellement à intégrer ce que l'on identifie dans la littérature par les effets d'externalités spatiales, c'est-à-dire capter l'influence des caractéristiques d'un voisin sur le comportement d'intérêt d'une observation donnée (voir Figure x).

Plusieurs avantages sont liés à cette spécification. D'une part, cette approche peut se faire simplement en ajoutant des variables à l'équation de départ, soit la spécification du PGD original. La création de variable indépendantes, supposées exogènes, décalées spatialement peut être effectuée de manière simple (voir figure 2.29). D'autre part, ce modèle peut être estimé par moindres carrés ordinaires, ce qui n'est pas possible avec les autres spécifications.

Dans un modèle SLX, l'autocorrélation spatiale est intégrée au niveau des variables indépendantes. Autrement dit, les variables indépendantes spatialement décalées (WX) sont introduites aussi dans le modèle. Par conséquent, la valeur de chaque unité spatiale du modèle est ainsi expliquée à la fois par ses propres caractéristiques et celles dans le voisinage ou à proximité en fonction de la matrice de pondération spatiale (W).

Note

Rappel sur les variables spatialement décalées

Dans le chapitre 2 sur l'autocorrélation spatiale, nous avons vu comment calculer une variable spatialement décalée avec une matrice de pondération spatiale ([@fig-Chap02FigureVariableSpatialementDecalee](#)). À titre de rappel, lorsque cette dernière est standardisée en ligne, elle correspond à la valeur moyenne dans le voisinage.

Le modèle SLX prend la spécification suivante :

$$y = \iota\alpha + X\beta + WX\theta + \varepsilon \quad (2.1)$$

Où :

- y , est la variable dépendante, soit un vecteur de dimension $(N \times 1)$ où N est le nombre total d'observations mobilisées dans l'analyse, avec $i = 1, 2, \dots, N$.
- ι est un vecteur de dimension $(N \times 1)$ comportant uniquement des valeurs de 1.
- X , une matrice de dimension $(N \times K)$ renfermant l'ensemble des K vecteurs de variables explicatives en plus d'une colonne de 1, dans la première colonne de la matrice, pour la constante, d'où $(K + 1)$.
- α est un scalaire identifiant l'ordonnée à l'origine.
- β , est un vecteur de dimension $(K + 1)$ qui renferme l'ensemble des coefficients de régression, pour les K variables indépendantes et la constante.

- WX est une matrice de variables indépendantes décalées spatialement, résultant d'une opération matricielle simple, soit $WX = W \times X$, où W est de dimension (NN) , X est de dimension $(N \times K)$, d'où WX est de dimension $(N \times K)$, où chaque observations représente la moyenne des valeurs des variables indépendantes autour d'une observation donnée.
- θ est un vecteur de coefficients associés aux valeurs décalées spatialement des variables indépendantes (excluant la constante) de dimension $(K \times 1)$.
- ε , un vecteur de dimension $(N \times 1)$ des termes d'erreurs.

Le PGD suggère que la valeur de chaque unité spatiale du modèle est ainsi expliquée à la fois par ses propres caractéristiques et celles de ses voisins ou des observations à proximité en fonction de la matrice de pondération spatiale (W).

Une des particularités du modèle SLX est qu'il introduit une complexité dans l'interprétation des résultats et le calcul des effets marginaux puisque la variable x_k apparaît à deux endroits dans le modèle : d'abord dans la matrice des variables indépendantes originales (X) et ensuite dans la matrice de variables indépendantes décalées spatialement (WX). Lorsque la matrice de pondérations est standardisée en ligne, le calcul des effets marginaux est alors donné par la dérivée partielle suivante :

$$\frac{\partial y}{\partial x_k} = \mathbf{I}\beta_k + W\theta_k \quad (2.2)$$

Pour une matrice de pondérations standardisées en ligne, cette expression se réduit à la valeur du coefficient associé à la variable indépendante originale, β_k , en plus de la valeur du coefficient associé à la variable décalée spatialement, θ_k . L'expression synthétise l'effet marginal total, alors que le coefficient β_k est habituellement désigné par l'effet direct et le coefficient θ_k synthétise l'effet indirect, puisque venant des voisins.

C'est d'ailleurs la valeur du coefficient θ_k qui introduit ce que l'on qualifie d'externalité spatiale. Il permet d'exprimer comment la variable dépendante varie lorsque les caractéristiques des voisins changent. Les changements dans la variable d'intérêt peuvent venir d'une variation des caractéristiques des voisins.

Ce modèle est aussi désigné sous le terme d'effet spatial local, par opposition à l'effet global (voir modèle SAR, section 2.2.4). La variation des caractéristiques des voisins a une portée limitée sur le changement de valeurs de la variable dépendante. Seulement certaines observations sont affectées : celles dont les caractéristiques des voisins ont changé.

Si le modèle SLX offre une solution intéressante pour régler le potentiel problème d'autocorrélation spatiale des résidus, rien n'assure pour autant qu'il permet de régler tous les problèmes, même si les coefficients associés aux variables décalées spatialement sont statistiquement significatifs. L'inclusion de variables indépendantes additionnelles peut ne pas suffire à capter ce qui, au départ dans la régression par MCO, se cache dans les résidus du modèle. Un test d'autocorrélation spatiale sur les résidus du modèle SLX est un réflexe nécessaire à avoir.

2.2.3 Mise en œuvre dans R

Le modèle SLX est construit avec la fonction `lmSLX` du *package* `spatialreg` (Bivand, Millo et Piras 2021). Remarquez, dans le code ci-dessous, le paramètre `listw=W.Rook` qui est utilisé pour spécifier la matrice de pondération spatiale.

```
## Chargement des packages et des données
library(sf)
library(tmap)
library(spdep)
library(spatialreg)
load("data/Lyon.Rdata")
## Matrice de contiguïté selon le partage d'un segment (Rook)
Rook <- poly2nb(LyonIris, queen=FALSE)
W.Rook <- nb2listw(Rook, zero.policy=TRUE, style = "W")
## Construction du modèle MCO
Modele.MCO <- lm(N02 ~ Pct0_14+Pct_65+Pct_Img+Pct_brevet+NivVieMed,
                 data = LyonIris)
## Construction du modèle
Modele.SLX <- lmSLX(N02 ~ Pct0_14+Pct_65+Pct_Img+Pct_brevet+NivVieMed,
                   listw=W.Rook,      # matrice de pondération spatiale
                   data = LyonIris) # dataframe
## Résultats du modèle
summary(Modele.SLX)
```

Call:

```
lm(formula = formula(paste("y ~ ", paste(colnames(x)[-1], collapse = "+"))),
   data = as.data.frame(x), weights = weights)
```

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	5.068e+01	4.188e+00	1.210e+01	1.040e-29
Pct0_14	-2.040e-01	6.268e-02	-3.255e+00	1.211e-03
Pct_65	-3.771e-02	5.361e-02	-7.033e-01	4.822e-01
Pct_Img	1.041e-01	4.849e-02	2.146e+00	3.235e-02
Pct_brevet	-7.363e-02	3.550e-02	-2.074e+00	3.857e-02
NivVieMed	-1.844e-01	1.106e-01	-1.667e+00	9.617e-02
lag.Pct0_14	-7.759e-01	1.030e-01	-7.537e+00	2.315e-13
lag.Pct_65	-6.454e-02	9.115e-02	-7.081e-01	4.792e-01
lag.Pct_Img	6.465e-01	8.593e-02	7.524e+00	2.526e-13
lag.Pct_brevet	-3.013e-01	6.157e-02	-4.893e+00	1.344e-06
lag.NivVieMed	-1.805e-02	1.750e-01	-1.031e-01	9.179e-01

⚠ Attention**Effets directs, indirects et totaux**

La formulation d'un modèle SLX implique deux types d'effets pour les variables indépendantes (X) :

- les **effets directs**, soit ceux des caractéristiques des entités spatiales. Ils correspondent aux coefficients β des variables indépendantes (X). Autrement dit, pour une observation i , à chaque augmentation d'une unité d'une caractéristique X , la valeur de y_i va varier (augmenter ou diminuer) en fonction du coefficient β .
- les **effets indirects**, soit ceux des caractéristiques des entités spatiales voisines ou proches définies selon la matrice de pondération spatiale. Ils correspondent aux coefficients θ des variables indépendantes spatialement décalées (WX). Autrement dit, les valeurs de WX des entités spatiales proches ou voisines j de i vont aussi être amenées à varier, impactant alors les valeurs y_j selon les coefficients θ .
- Pour calculer l'impact total, il suffit de sommer son effet direct (β_k) et son effet indirect (θ_k) pour obtenir son effet total.

Le code suivant permet de calculer ces effets directs et indirects.

```
## Effets directs, indirects et totaux (uniquement les coefficients)
impacts(Modele.SLX)
```

Impact measures (SLX, glht):

	Direct	Indirect	Total
Pct0_14	-0.20403803	-0.77590830	-0.9799463
Pct_65	-0.03770918	-0.06453809	-0.1022473
Pct_Img	0.10406359	0.64653923	0.7506028
Pct_brevet	-0.07363272	-0.30128171	-0.3749144
NivVieMed	-0.18440960	-0.01804718	-0.2024568

```
## Effets directs, indirects et totaux (coefficients, valeurs de z et de p)
summary(impacts(Modele.SLX))
```

Impact measures (SLX, glht, n-k):

	Direct	Indirect	Total
Pct0_14	-0.20403803	-0.77590830	-0.9799463
Pct_65	-0.03770918	-0.06453809	-0.1022473
Pct_Img	0.10406359	0.64653923	0.7506028
Pct_brevet	-0.07363272	-0.30128171	-0.3749144
NivVieMed	-0.18440960	-0.01804718	-0.2024568

=====

Standard errors:

	Direct	Indirect	Total
Pct0_14	0.06268202	0.10295210	0.10045332
Pct_65	0.05361420	0.09114695	0.08556272
Pct_Img	0.04849085	0.08593145	0.08060028

```
Pct_brevet 0.03549819 0.06157121 0.05975821
NivVieMed 0.11063207 0.17499339 0.14911021
=====
```

Z-values:

	Direct	Indirect	Total
Pct0_14	-3.2551283	-7.5365951	-9.755241
Pct_65	-0.7033432	-0.7080664	-1.194998
Pct_Img	2.1460460	7.5238953	9.312658
Pct_brevet	-2.0742665	-4.8932234	-6.273857
NivVieMed	-1.6668729	-0.1031306	-1.357766

p-values:

	Direct	Indirect	Total
Pct0_14	0.0011334	4.8184e-14	< 2.22e-16
Pct_65	0.4818419	0.47890	0.23209
Pct_Img	0.0318693	5.3069e-14	< 2.22e-16
Pct_brevet	0.0380546	9.9198e-07	3.5221e-10
NivVieMed	0.0955397	0.91786	0.17454

VOIR AVEC JEAN!!! À la lecture des valeurs de p , nous constatons que seule la variable Pct0_14 a un impact direct et indirect significatif au seuil 0,01. L'augmentation d'un point de pourcentage de la population de moins de 15 ans est associé localement à une réduction de 0,20 de la concentration annuelle du dioxyde d'azote. Chez les entités voisines, cette réduction est de 0,78. L'effet total est donc une réduction de 0,98.

Dépendance spatiale du modèle SLX?

Ce modèle a-t-il corrigé le problème de dépendance spatiale du modèle de régression linéaire classique? Avec une valeur du I de Moran de 0,605 ($p < 0,001$), les résidus sont toujours fortement autocorrélés spatialement (figure 2.1).

```
lm.morantest(Modele.SLX, W.Rook, alternative="two.sided")
```

Global Moran I for regression residuals

data:

```
model: lm(formula = formula(paste("y ~ ", paste(colnames(x)[-1],
collapse = "+"))), data = as.data.frame(x), weights = weights)
weights: W.Rook
```

Moran I statistic standard deviate = 21.951, p-value < 2.2e-16

alternative hypothesis: two.sided

sample estimates:

Observed Moran I	Expectation	Variance
0.6046602748	-0.0072844321	0.0007771643

```
LyonIris$SLX.Residus <- residuals(Modele.SLX)
tm_shape(LyonIris)+
  tm_fill(col="SLX.Residus", n = 5, style = "quantile",
          legend.format = list(text.separator = "à"),
          palette = "-RdBu", title = "Résidus") +
  tm_layout(frame=FALSE) +
  tm_scale_bar(breaks = c(0,5))
```




Figure 2.1: Cartographie des résidus du modèle SLX

2.2.4 Modèle SAR : autocorrélation spatiale sur la variable dépendante

Dans le modèle SAR (aussi appelé SAR-LAG), l'autocorrélation spatiale est intégrée au niveau de la variable dépendante (Wy), qui est ainsi spatialement décalée. L'idée générale est que la valeur de la variable dépendante pour une observation (y_i) peut être influencée par les valeurs de y des observations voisines et proches. L'exemple le plus classique est le prix de vente des maisons : il est influencé à la fois par les caractéristiques intrinsèques de la maison (X , par exemple, la superficie habitable, le nombre de chambres à coucher, de salles de bains, etc.) et par le prix de vente des maisons voisines (Wy). Jean Dubé et Diègo Legros (2014) qualifient ce phénomène « **d'effets d'entraînement ou d'effets de débordement** (*spillover effects*) » (2014, 123). L'équation du modèle SAR s'écrit alors :

$$y = Wy\rho + X\beta + \epsilon \quad (2.3)$$

avec :

- y , la variable dépendante.
- W , la matrice de pondération spatiale.
- Wy , la variable dépendante spatialement décalée.
- ρ (prononcez *rho*), le coefficient de la variable dépendante spatialement décalée. Il varie de -1 à 1.
- X , les variables indépendantes.
- β , les coefficients des variables indépendantes.
- ϵ , les résidus.

Construction du modèle SAR dans R

Le modèle SAR est construit avec la fonction `lagsarlm` du *package* `spatialreg`.

```
## Construction du modèle
Modele.SAR <- lagsarlm(N02 ~ Pct0_14+Pct_65+Pct_Img+Pct_brevet+NivVieMed,
                      listw=W.Rook, # matrice de pondération spatiale
                      data = LyonIris, # dataframe
                      type = 'lag') # Modèle lag par défaut

## Résultats du modèle
summary(Modele.SAR, Nagelkerke=TRUE)
```

```
Call:lagsarlm(formula = N02 ~ Pct0_14 + Pct_65 + Pct_Img + Pct_brevet +
  NivVieMed, data = LyonIris, listw = W.Rook, type = "lag")
```

Residuals:

	Min	1Q	Median	3Q	Max
	-12.86859	-1.88111	-0.49760	0.94464	18.21351

Type: lag

Coefficients: (asymptotic standard errors)

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	7.838906	1.646232	4.7617	1.919e-06
Pct0_14	-0.098708	0.030554	-3.2306	0.001235

Pct_65	-0.034543	0.026957	-1.2814	0.200044
Pct_Img	0.030241	0.024491	1.2348	0.216917
Pct_brevet	-0.019234	0.017855	-1.0772	0.281384
NivVieMed	-0.098413	0.048985	-2.0090	0.044534

Rho: 0.87939, LR test value: 620.31, p-value: < 2.22e-16

Asymptotic standard error: 0.01942

z-value: 45.283, p-value: < 2.22e-16

Wald statistic: 2050.5, p-value: < 2.22e-16

Log likelihood: -1366.157 for lag model

ML residual variance (sigma squared): 10.181, (sigma: 3.1908)

Nagelkerke pseudo-R-squared: 0.78962

Number of observations: 506

Number of parameters estimated: 8

AIC: 2748.3, (AIC for lm: 3366.6)

LM test for residual autocorrelation

test value: 0.6198, p-value: 0.43112

Dans les résultats ci-dessus, la valeur de ρ est de 0,88 (LR = 620, $p < 0,001$), traduisant un très fort effet d'entraînement. Autrement dit, lorsqu'en moyenne la concentration de dioxyde d'azote augmente dans les IRIS voisines (W_y), elle augmente aussi fortement chaque IRIS (y).

⚠ Attention**Effets directs, indirects et totaux**

Tout comme le modèle SLX vu précédemment, la formulation du modèle SAR-LAG implique des effets particuliers. Reprenons l'exemple d'un modèle prédisant le prix de vente des maisons avec cette fois-ci un modèle de type SAR-LAG :

1. L'augmentation de la superficie du jardin de la maison i va faire augmenter le prix de la maison i (y_i).
2. Cette augmentation de prix de la maison i aura un impact sur les voisins de i , soit les maisons j , car leur prix dépend du prix de la maison i au travers du terme $W_{ij}\rho$ du modèle. Par exemple, si ρ vaut 0,8, alors 80% de l'augmentation du prix de i va se répercuter sur le prix des maisons j .
3. De même, les voisines des maisons j , les maisons k vont aussi être impactées par le changement de prix des maisons j et ainsi de suite de voisins en voisins.
4. Au final, la maison i verra son prix augmenter encore plus, car le prix de ses voisines aura augmenté par effet de rétroaction.

Ce processus de propagation est appelé l'effet d'entraînement ou de débordement (*spillover*) en économétrie. L'effet original de l'augmentation de la taille du jardin sur la maison i , combiné à l'augmentation par rétroaction, est appelé l'effet direct. L'effet cumulé de l'augmentation de la taille du jardin sur toutes les autres maisons ($\neq i$) est appelé l'effet indirect. La somme des effets indirects et des directs est appelée effets totaux. À nouveau, il est possible d'utiliser la fonction `impacts` pour calculer ces effets directs et indirects.

```
## Effets directs, indirects et totaux (uniquement les coefficients)
impacts(Modele.SAR, listw = W.Rook, R = 999)
```

Impact measures (lag, exact):

	Direct	Indirect	Total
Pct0_14	-0.13878038	-0.6796248	-0.8184052
Pct_65	-0.04856624	-0.2378349	-0.2864012
Pct_Img	0.04251743	0.2082131	0.2507306
Pct_brevet	-0.02704205	-0.1324283	-0.1594703
NivVieMed	-0.13836534	-0.6775923	-0.8159576

```
## Effets directs, indirects et totaux (coefficients, valeurs de z et de p)
summary(impacts(Modele.SAR, listw = W.Rook, R = 999), zstats = TRUE, short = TRUE)
```

Impact measures (lag, exact):

	Direct	Indirect	Total
Pct0_14	-0.13878038	-0.6796248	-0.8184052
Pct_65	-0.04856624	-0.2378349	-0.2864012
Pct_Img	0.04251743	0.2082131	0.2507306
Pct_brevet	-0.02704205	-0.1324283	-0.1594703
NivVieMed	-0.13836534	-0.6775923	-0.8159576

Simulation results (variance matrix):

Simulated standard errors

	Direct	Indirect	Total
Pct0_14	0.04153412	0.2534874	0.2897517
Pct_65	0.03706929	0.1938247	0.2297786
Pct_Img	0.03579497	0.1870352	0.2218454
Pct_brevet	0.02576469	0.1325128	0.1577372
NivVieMed	0.06812106	0.3659834	0.4302887

Dépendance spatiale du modèle SAR?

Ce modèle a-t-il corrigé le problème de dépendance spatiale du modèle de régression linéaire classique? Avec une valeur du I de Moran de -0,014 ($p = 0,654$), les résidus ne sont plus spatialement autocorrélés (figure 2.2).

```
## Autocorrélation spatiale des résidus
moran.mc(resid(Modele.SAR), W.Rook, nsim=999)
```

Monte-Carlo simulation of Moran I

```
data: resid(Modele.SAR)
weights: W.Rook
number of simulations + 1: 1000

statistic = -0.014281, observed rank = 338, p-value = 0.662
alternative hypothesis: greater
```

```
## Cartographie des résidus
LyonIris$SAR.Residus <- resid(Modele.SAR)
tm_shape(LyonIris)+
  tm_fill(col="SAR.Residus", n = 5, style = "quantile",
          legend.format = list(text.separator = "à"),
          palette = "-RdBu", title = "Résidus") +
  tm_layout(frame=FALSE) +
  tm_scale_bar(breaks = c(0,5))
```




Figure 2.2: Cartographie des résidus du modèle SAR

2.2.5 Modèle SEM : autocorrélation spatiale sur le terme d'erreur

Dans le modèle SEM (*Spatial Error Model*, appelé aussi *SAR-ERROR*), l'intégration de l'autocorrélation spatiale est réalisée sur le terme d'erreur, ce qui pourrait se justifier par l'omission d'une variable dépendante spatialement structurée (Dubé et Legros 2014, 126). L'équation du modèle SEM s'écrit :

$$y = X\beta + u, u = \lambda W u + \epsilon \quad (2.4)$$

avec :

- y , la variable dépendante.
- W , la matrice de pondération spatiale.
- λ (prononcez *lambda*), le coefficient sur le terme d'erreur spatialement décalé. Il varie de -1 à 1.
- X , les variables indépendantes.
- β , les coefficients des variables indépendantes.
- ϵ , les résidus.

Construction du modèle SAR dans R

Le modèle SEM est construit avec la fonction `errorsarlm` du *package* `spatialreg`.

```
## Construction du modèle
Modele.SEM <- errorsarlm(N02 ~ Pct0_14+Pct_65+Pct_Img+Pct_brevet+NivVieMed,
                        listw=W.Rook,      # matrice de pondération spatiale
                        data = LyonIris) # dataframe
## Résultats du modèle
summary(Modele.SEM, Nagelkerke=TRUE)
```

```
Call:errorsarlm(formula = N02 ~ Pct0_14 + Pct_65 + Pct_Img + Pct_brevet +
  NivVieMed, data = LyonIris, listw = W.Rook)
```

Residuals:

	Min	1Q	Median	3Q	Max
	-12.86150	-1.83161	-0.44106	0.91029	17.94924

Type: error

Coefficients: (asymptotic standard errors)

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	30.544576	2.358173	12.9526	< 2e-16
Pct0_14	-0.035019	0.033393	-1.0487	0.29431
Pct_65	-0.026039	0.028970	-0.8988	0.36874
Pct_Img	-0.016770	0.026176	-0.6407	0.52175
Pct_brevet	0.023708	0.019074	1.2430	0.21388
NivVieMed	-0.146309	0.060273	-2.4274	0.01521

Lambda: 0.91138, LR test value: 613.15, p-value: < 2.22e-16

Asymptotic standard error: 0.01651
 z-value: 55.201, p-value: < 2.22e-16
 Wald statistic: 3047.2, p-value: < 2.22e-16

Log likelihood: -1369.737 for error model
 ML residual variance (sigma squared): 9.9971, (sigma: 3.1618)
 Nagelkerke pseudo-R-squared: 0.78662
 Number of observations: 506
 Number of parameters estimated: 8
 AIC: 2755.5, (AIC for lm: 3366.6)

Dans les résultats ci-dessus, la valeur de λ est de 0,91 (LR = 613, $p < 0,001$), traduisant une très forte autocorrélation spatiale sur le terme d'erreur.

Dépendance spatiale du modèle SEM?

Ce modèle a-t-il corrigé le problème de dépendance spatiale du modèle de régression linéaire classique? Avec une valeur du I de Moran de -0,013 ($p = 0,614$), les résidus ne sont plus spatialement autocorrélés.

```
## Autocorrélation spatiale des résidus
moran.mc(resid(Modele.SEM), W.Rook, nsim=999)
```

Monte-Carlo simulation of Moran I

```
data: resid(Modele.SEM)
weights: W.Rook
number of simulations + 1: 1000
```

```
statistic = -0.011827, observed rank = 366, p-value = 0.634
alternative hypothesis: greater
```

2.2.6 Modèle SDM : autocorrélation spatiale sur la variable dépendante et les variables indépendantes

Le modèle SDM (*Spatial Durbin Model*) est un modèle mixte qui intègre à la fois l'autocorrélation spatiale sur la variable dépendante (Wy , **effets d'entraînement ou de débordement**) et sur les variables indépendantes (WX , **externalités**). Il s'écrit alors :

$$y = Wy\rho + X\beta + WX\theta + \epsilon \quad (2.5)$$

avec :

- y , la variable dépendante.
- W , la matrice de pondération spatiale.
- Wy , la variable dépendante spatialement décalée.

- ρ , le coefficient de la variable dépendante spatialement décalée.
- X , les variables indépendantes.
- β , les coefficients des variables indépendantes.
- WX , les variables indépendantes spatiales décalées.
- θ , les coefficients des variables indépendantes spatiales décalées.
- ϵ , les résidus.

Construction du modèle SDM dans R

Le modèle SDM est construit avec la fonction `lagsarlm` du *package* `spatialreg`. Notez que le paramètre `type = "mixed"` spécifie l'utilisation d'un modèle mixte.

```
## Construction du modèle
Modele.DurbinSpatial <- lagsarlm(N02 ~ Pct0_14+Pct_65+Pct_Img+Pct_brevet+NivVieMed,
                                listw = W.Rook,      # matrice de pondération spatiale
                                data = LyonIris,      # dataframe
                                type = "mixed")
## Résultats du modèle
summary(Modele.DurbinSpatial, Nagelkerke=TRUE)
```

```
Call:lagsarlm(formula = N02 ~ Pct0_14 + Pct_65 + Pct_Img + Pct_brevet +
              NivVieMed, data = LyonIris, listw = W.Rook, type = "mixed")
```

Residuals:

	Min	1Q	Median	3Q	Max
	-12.60922	-1.77753	-0.43909	0.99252	18.15526

Type: mixed

Coefficients: (asymptotic standard errors)

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	8.1130457	2.5671301	3.1604	0.001576
Pct0_14	-0.0574046	0.0344908	-1.6643	0.096043
Pct_65	-0.0238715	0.0293647	-0.8129	0.416256
Pct_Img	0.0048364	0.0266560	0.1814	0.856025
Pct_brevet	0.0112746	0.0195259	0.5774	0.563656
NivVieMed	-0.1463876	0.0605853	-2.4162	0.015682
lag.Pct0_14	-0.1242574	0.0581170	-2.1381	0.032512
lag.Pct_65	0.0255480	0.0499646	0.5113	0.609125
lag.Pct_Img	0.1559952	0.0482138	3.2355	0.001214
lag.Pct_brevet	-0.0883930	0.0342496	-2.5809	0.009856
lag.NivVieMed	0.1032469	0.0960201	1.0753	0.282257

Rho: 0.84127, LR test value: 492.38, p-value: < 2.22e-16

Asymptotic standard error: 0.023363

z-value: 36.009, p-value: < 2.22e-16

Wald statistic: 1296.7, p-value: < 2.22e-16

```
Log likelihood: -1353.106 for mixed model
ML residual variance (sigma squared): 9.9845, (sigma: 3.1598)
Nagelkerke pseudo-R-squared: 0.8002
Number of observations: 506
Number of parameters estimated: 13
AIC: 2732.2, (AIC for lm: 3222.6)
LM test for residual autocorrelation
test value: 0.0748, p-value: 0.78447
```

Effets directs, indirects et totaux

```
# Effets directs, indirects et totaux (uniquement les coefficients)
impacts(Modele.DurbinSpatial, listw = W.Rook, R = 999)
```

```
Impact measures (mixed, exact):
```

	Direct	Indirect	Total
Pct0_14	-0.12369039	-1.02079497	-1.14448536
Pct_65	-0.02177191	0.03233406	0.01056215
Pct_Img	0.06632543	0.94692639	1.01325182
Pct_brevet	-0.01903815	-0.46681402	-0.48585217
NivVieMed	-0.15403413	-0.11775603	-0.27179016

```
# Effets directs, indirects et totaux (coefficients, valeurs de z et de p)
summary(impacts(Modele.DurbinSpatial, listw = W.Rook, R = 999), zstats = TRUE, short = TRUE)
```

```
Impact measures (mixed, exact):
```

	Direct	Indirect	Total
Pct0_14	-0.12369039	-1.02079497	-1.14448536
Pct_65	-0.02177191	0.03233406	0.01056215
Pct_Img	0.06632543	0.94692639	1.01325182
Pct_brevet	-0.01903815	-0.46681402	-0.48585217
NivVieMed	-0.15403413	-0.11775603	-0.27179016

```
=====
Simulation results ( variance matrix):
=====
Simulated standard errors
```

	Direct	Indirect	Total
Pct0_14	0.04454971	0.3493935	0.3779545
Pct_65	0.03547059	0.2723682	0.2933346
Pct_Img	0.03280077	0.2697592	0.2887926
Pct_brevet	0.02481553	0.1939244	0.2097555
NivVieMed	0.07049084	0.4833295	0.5197905

```

Simulated z-values:
```

	Direct	Indirect	Total
Pct0_14	-2.8084106	-2.95457418	-3.06233456
Pct_65	-0.6853602	0.06893298	-0.01886917
Pct_Img	2.0134436	3.51413828	3.51121655
Pct_brevet	-0.7718079	-2.38113048	-2.29272611
NivVieMed	-2.1854398	-0.22296548	-0.50370158

Simulated p-values:

	Direct	Indirect	Total
Pct0_14	0.0049787	0.00313101	0.00219618
Pct_65	0.4931166	0.94504296	0.98494547
Pct_Img	0.0440680	0.00044118	0.00044606
Pct_brevet	0.4402282	0.01725960	0.02186378
NivVieMed	0.0288566	0.82356237	0.61447110

Dépendance spatiale du modèle SDM?

```
moran.mc(resid(Modele.DurbinSpatial), W.Rook, nsim=999)
```

Monte-Carlo simulation of Moran I

```
data: resid(Modele.DurbinSpatial)
weights: W.Rook
number of simulations + 1: 1000
```

```
statistic = -0.0046127, observed rank = 494, p-value = 0.506
alternative hypothesis: greater
```

2.2.7 Modèle SDEM : autocorrélation spatiale sur les variables indépendantes et sur le terme d'erreur

Le modèle SDEM (*Spatial Durbin Error Model* en anglais) est un autre modèle mixte qui intègre à la fois l'autocorrélation spatiale sur les valeurs indépendantes (WX , **externalités**) et sur le terme d'erreur ($u = \lambda Wu + \epsilon$). Il s'écrit alors :

$$y = X\beta + WX\theta + u, u = \lambda Wu + \epsilon \quad (2.6)$$

avec :

- y , la variable dépendante.
- W , la matrice de pondération spatiale.
- X , les variables indépendantes.
- β , les coefficients des variables indépendantes.
- WX , les variables dépendantes spatiales décalées.
- θ , les coefficients des variables indépendantes spatiales décalées.

- λ (prononcez *lambda*), le coefficient sur le terme d'erreur spatialement décalé.
- ϵ , les résidus.

Construction du modèle SDEM dans R

Le modèle SDEM est construit avec la fonction `errorsarlm` du *package* `spatialreg`. Notez que le paramètre `etype = "mixed"` spécifie l'utilisation d'un modèle mixte.

```
## Construction du modèle
Modele.DurbinErreur <- errorsarlm(N02 ~ Pct0_14+Pct_65+Pct_Img+Pct_brevet+NivVieMed,
                                listw=W.Rook,      # matrice de pondération spatiale
                                data = LyonIris,    # dataframe
                                etype = 'emixed')

## Résultats du modèle
summary(Modele.DurbinErreur, Nagelkerke=TRUE)
```

```
Call:errorsarlm(formula = N02 ~ Pct0_14 + Pct_65 + Pct_Img + Pct_brevet +
  NivVieMed, data = LyonIris, listw = W.Rook, etype = "emixed")
```

Residuals:

	Min	1Q	Median	3Q	Max
	-12.99324	-1.82407	-0.45644	1.06084	18.21108

Type: error

Coefficients: (asymptotic standard errors)

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	37.061010	6.501018	5.7008	1.192e-08
Pct0_14	-0.081998	0.041699	-1.9664	0.04925
Pct_65	-0.026329	0.034714	-0.7585	0.44817
Pct_Img	0.004656	0.031028	0.1501	0.88072
Pct_brevet	0.009785	0.023884	0.4097	0.68203
NivVieMed	-0.167855	0.068005	-2.4683	0.01358
lag.Pct0_14	-0.176747	0.102345	-1.7270	0.08417
lag.Pct_65	0.010533	0.089183	0.1181	0.90599
lag.Pct_Img	0.092785	0.079704	1.1641	0.24437
lag.Pct_brevet	-0.038048	0.056688	-0.6712	0.50211
lag.NivVieMed	-0.102531	0.172405	-0.5947	0.55204

Lambda: 0.8976, LR test value: 464.09, p-value: < 2.22e-16

Asymptotic standard error: 0.018242

z-value: 49.204, p-value: < 2.22e-16

Wald statistic: 2421, p-value: < 2.22e-16

Log likelihood: -1367.25 for error model

ML residual variance (sigma squared): 10.046, (sigma: 3.1696)

Nagelkerke pseudo-R-squared: 0.78871

Number of observations: 506
 Number of parameters estimated: 13
 AIC: 2760.5, (AIC for lm: 3222.6)

Effets directs, indirects et totaux

```
## Effets directs, indirects et totaux (uniquement les coefficients)
impacts(Modele.DurbinErreur, listw = W.Rook, R = 999)
```

Impact measures (SDEM, glht):

	Direct	Indirect	Total
Pct0_14	-0.081997642	-0.17674683	-0.25874447
Pct_65	-0.026329370	0.01053248	-0.01579689
Pct_Img	0.004656039	0.09278511	0.09744115
Pct_brevet	0.009784961	-0.03804813	-0.02826317
NivVieMed	-0.167855498	-0.10253070	-0.27038620

```
## Effets directs, indirects et totaux (coefficients, valeurs de z et de p)
summary(impacts(Modele.DurbinErreur, listw = W.Rook, R = 999), zstats = TRUE, short = TRUE)
```

Impact measures (SDEM, glht, n):

	Direct	Indirect	Total
Pct0_14	-0.081997642	-0.17674683	-0.25874447
Pct_65	-0.026329370	0.01053248	-0.01579689
Pct_Img	0.004656039	0.09278511	0.09744115
Pct_brevet	0.009784961	-0.03804813	-0.02826317
NivVieMed	-0.167855498	-0.10253070	-0.27038620

Standard errors:

	Direct	Indirect	Total
Pct0_14	0.04169878	0.10234506	0.13146453
Pct_65	0.03471367	0.08918350	0.11192948
Pct_Img	0.03102807	0.07970364	0.09949722
Pct_brevet	0.02388387	0.05668833	0.07344175
NivVieMed	0.06800483	0.17240549	0.21172909

Z-values:

	Direct	Indirect	Total
Pct0_14	-1.9664279	-1.7269698	-1.9681695
Pct_65	-0.7584727	0.1180989	-0.1411325
Pct_Img	0.1500589	1.1641264	0.9793354
Pct_brevet	0.4096890	-0.6711810	-0.3848379
NivVieMed	-2.4682880	-0.5947067	-1.2770385

p-values:

	Direct	Indirect	Total
Pct0_14	0.049249	0.084173	0.049049
Pct_65	0.448168	0.905989	0.887765
Pct_Img	0.880718	0.244373	0.327414
Pct_brevet	0.682034	0.502105	0.700358
NivVieMed	0.013576	0.552040	0.201589

Dépendance spatiale du modèle SDEM?

Avec une valeur du I de Moran de -0,010 ($p = 0,619$), les résidus du modèle SDEM ne sont pas spatialement autocorrélés.

```
moran.mc(resid(Modele.DurbinErreur), W.Rook, nsim=999)
```

Monte-Carlo simulation of Moran I

```
data: resid(Modele.DurbinErreur)
weights: W.Rook
number of simulations + 1: 1000
```

```
statistic = -0.010362, observed rank = 430, p-value = 0.57
alternative hypothesis: greater
```

2.3 Quel modèle choisir?

2.3.1 Tests du multiplicateur de Lagrange sur le modèle MCO

L'utilisation des tests du multiplicateur de Lagrange (simple et robuste) a été largement popularisée par Anselin *et al.* (1996) pour vérifier si le recours à un modèle autorégressif est nécessaire, comparativement à un modèle de régression classique (MCO). Les tests sont calculés sur le modèle MCO avec la fonction `lm.LMtests` et une matrice de pondération spatiale. Ces tests permettent aussi de choisir entre les modèles SAR et SEM. La démarche suivante peut être utilisée pour choisir un modèle :

1. Si toutes les valeurs des tests (simples et robustes) sont non significatives ($p > 0,05$), alors le recours à un modèle autorégressif n'est pas nécessaire. Nous pouvons conserver le modèle de régression classique (MCO).
2. Si les valeurs de `LMlag` ou `RLMlag` sont non significatives ($p > 0,05$), alors le recours au modèle SAR n'est pas nécessaire.
3. Si les valeurs de `LMerr` ou `RLMerr` sont non significatives ($p > 0,05$), alors le recours au modèle SEM n'est pas nécessaire.
4. Si les valeurs de `RLMlag` et `RLMerr` sont significatives ($p < 0,001$), nous choisissons le modèle ayant la plus forte statistique.

Dans les résultats ci-dessous, nous ne retenons pas le modèle SEM car la valeur de 0,740 pour le `RLMerr` n'est pas significative ($p = 0,3898$). Par contre, les valeurs de `LMlag` et de `RLMlag` (555 et 123) sont significatives, ce qui justifie la sélection du modèle SAR.

```
summary(lm.LMtests(model = Modele.MCO,
                  listw = W.Rook,
                  test = c("LMlag", "LMerr", "RLMlag", "RLMerr")))
```

Rao's score (a.k.a Lagrange multiplier) diagnostics for spatial dependence

data:

model: `lm(formula = N02 ~ Pct0_14 + Pct_65 + Pct_Img + Pct_brevet + NivVieMed, data = LyonIris)`

test weights: `listw`

	statistic	parameter	p.value
RSlag	554.65778	1	<2e-16 ***
RSerr	432.83282	1	<2e-16 ***
adjRSlag	122.56452	1	<2e-16 ***
adjRSerr	0.73955	1	0.3898

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

2.3.2 Comparaison des modèles mixtes et non mixtes

Nous avons vu qu'il existe deux modèles mixtes (SDM et SDEM). Il convient alors de vérifier si le recours d'un modèle mixte est justifié comparativement à un modèle non mixte. Dans le code ci-dessous, nous vérifions si le modèle SDM est statistiquement différent du modèle SAR avec les fonctions `LR.Sarlm` et `anova`. Les résultats signalent un écart significatif des valeurs du log-vraisemblance (26,101, $p < 0,001$). Par conséquent, ce modèle mixte a un apport significatif.

```
## SDM et SEM sont-ils significativement différents?
LR.Sarlm(Modele.DurbinSpatial, Modele.SAR)
```

Likelihood ratio for spatial linear models

data:

Likelihood ratio = 26.101, df = 5, p-value = 8.528e-05

sample estimates:

Log likelihood of Modele.DurbinSpatial	Log likelihood of Modele.SAR
-1353.106	-1366.157

```
anova(Modele.DurbinSpatial, Modele.SAR)
```

	Model	df	AIC	logLik	Test	L.Ratio	p-value
Modele.DurbinSpatial	1	13	2732.2	-1353.1	1		
Modele.SAR	2	8	2748.3	-1366.2	2	26.101	8.5283e-05

À l'inverse, la différence entre les valeurs du log-vraisemblance des modèles SDEM et SEM n'est pas significative (4,9728, $p = 0,42$), signalant que l'utilisation d'un modèle SDEM comparativement à un modèle SEM n'est pas nécessaire.

```
## SDEM et SEM sont-ils significativement différents?
LR.Sarlm(Modele.DurbinErreur, Modele.SEM)
```

Likelihood ratio for spatial linear models

data:

Likelihood ratio = 4.9728, df = 5, p-value = 0.4192

sample estimates:

Log likelihood of Modele.DurbinErreur	Log likelihood of Modele.SEM
-1367.250	-1369.737

```
anova(Modele.DurbinErreur, Modele.SEM)
```

	Model	df	AIC	logLik	Test	L.Ratio	p-value
Modele.DurbinErreur	1	13	2760.5	-1367.2	1		
Modele.SEM	2	8	2755.5	-1369.7	2	4.9728	0.4192

2.3.3 Mesures AIC et BIC et dépendance spatiale

Le critère d'information d'Akaike (AIC) et le critère d'information bayésien (BIC) sont largement utilisés pour évaluer la qualité d'ajustement du modèle. Plus leurs valeurs sont faibles, meilleur est le modèle. Il est donc possible de comparer leurs valeurs pour les différents modèles (MCO, SLX, SAR, SEM, SDM et SDEM). Nous pouvons aussi comparer l'autocorrélation spatiale des résidus des modèles avec le I de Moran.

```
## Valeurs d'AIC et de BIC
AICs <- AIC(Modele.MCO, Modele.SLX, Modele.SAR, Modele.SEM,
            Modele.DurbinSpatial, Modele.DurbinErreur)
BICs <- BIC(Modele.MCO, Modele.SLX, Modele.SAR, Modele.SEM,
            Modele.DurbinSpatial, Modele.DurbinErreur)

## Autocorrélation spatiale des résidus
IMoran.MCO <- moran.mc(resid(Modele.MCO), W.Rook, nsim=999)
IMoran.SLX <- moran.mc(resid(Modele.SLX), W.Rook, nsim=999)
IMoran.SLM <- moran.mc(resid(Modele.SAR), W.Rook, nsim=999)
IMoran.SEM <- moran.mc(resid(Modele.SEM), W.Rook, nsim=999)
IMoran.DurbinS <- moran.mc(resid(Modele.DurbinSpatial), W.Rook, nsim=999)
IMoran.DurbinE <- moran.mc(resid(Modele.DurbinErreur), W.Rook, nsim=999)
MoranI.s <- c(IMoran.MCO$statistic, IMoran.SLX$statistic,
              IMoran.SLM$statistic, IMoran.SEM$statistic,
              IMoran.DurbinS$statistic, IMoran.DurbinE$statistic)
MoranI.p <- c(IMoran.MCO$p.value, IMoran.SLX$p.value,
```

```

      IMoran.SLM$p.value, IMoran.SEM$p.value,
      IMoran.DurbinS$p.value, IMoran.DurbinE$p.value)
## Tableau
Comparaison <- data.frame(Modele = c("MCO", "SLX", "SAR", "SEM", "Durbin S", "Durbin E"),
                          AIC = AICs$AIC,
                          BIC = BICs$BIC,
                          dl = AICs$df,
                          MoranI = MoranI.s,
                          MoranIp = MoranI.p)
Comparaison

```

	Modele	AIC	BIC	dl	MoranI	MoranIp
1	MCO	3366.626	3396.212	7	0.587312061	0.001
2	SLX	3222.594	3273.313	12	0.604660275	0.001
3	SAR	2748.314	2782.126	8	-0.014281059	0.691
4	SEM	2755.474	2789.286	8	-0.011826605	0.655
5	Durbin S	2732.212	2787.157	13	-0.004612686	0.510
6	Durbin E	2760.501	2815.446	13	-0.010361653	0.618

Quelques lignes de code suffisent pour créer deux graphiques permettant de comparer visuellement les résultats des différents modèles (figure 2.3). Les résultats démontrent que :

- Les modèles MCO et SLX ont un problème de dépendance spatiale puisque leurs résidus sont significativement autocorrélés spatialement. Par conséquent, ils ne devraient pas être retenus.
- Les modèles SDM, SAR et SEM sont les plus performants avec les valeurs d'AIC les plus faibles.

```

library(ggplot2)
library(ggpubr)
## Graphique pour l'autocorrélation spatiale
g1 <- ggplot(data=Comparaison, aes(x=reorder(Modele,MoranI), y=MoranI)) +
  geom_segment(aes(x=reorder(Modele, MoranI),
                           xend=reorder(Modele, MoranI),
                           y=0, yend=MoranI)) +
  geom_point( size=4,fill="red",shape=21)+
  xlab("Modèle") + ylab("I de Moran")+
  labs(title="Autocorrélation spatiale des résidus",
       caption="Plus la valeur du I de Moran est faible, \nmoins il y a d'autocorrélation spatiale.")
## Graphique pour les valeurs d'AIC
g2 <- ggplot(data=Comparaison, aes(x=reorder(Modele,AIC), y=AIC)) +
  geom_segment(aes(x=reorder(Modele, AIC),
                           xend=reorder(Modele, AIC),
                           y=0, yend=AIC)) +
  geom_point( size=4,fill="red",shape=21)+
  xlab("Modèle") + ylab("AIC")+
  labs(title="Qualité d'ajustement du modèle",

```

```
caption="Plus la valeur d'AIC est faible, \nplus le modèle est performant.")
## Figure avec les deux graphiques
ggarrange(g1, g2)
```




Figure 2.3: Comparaison des différents modèles

2.4 Quiz de révision

2.5 Exercices de révision

Exercice

Exercice 1. Réalisation de modèles de régression autorégressifs spatiaux

```
library(sf)
library(spatialreg)
# Matrice de contiguïté selon le partage d'un segment (Rook)
load("data/chap02/DonneesLyon.Rdata")
Rook <- poly2nb(LyonIris, queen=FALSE)
Rook <- poly2nb(LyonIris, queen=FALSE)
W.Rook <- nb2listw(Rook, zero.policy=TRUE, style = "W")
# Modèles
formule <- "PM25 ~ Pct0_14+Pct_65+Pct_Img+Pct_brevet+NivVieMed"
Modele.SLX <- à compléter
Modele.SAR <- à compléter
Modele.SEM <- à compléter
Modele.DurbinSpatial <- à compléter
Modele.DurbinErreur <- à compléter
```

Correction à la ?@sec-06071.

Exercice

Exercice 2. Réalisation d'un modèle GAM

```
library(sf)
library(mgcv)
load("data/chap02/DonneesLyon.Rdata")
# Ajout des coordonnées x et y
xy <- à compléter
LyonIris$X <- à compléter
LyonIris$Y <- à compléter
# Construction du modèle
formule <- "PM25 ~ Pct0_14+Pct_65+Pct_Img+Pct_brevet+NivVieMed"
Modele.GAM2 <- gam(NO2 ~ à compléter
                  à compléter,
                  data = LyonIris)
summary(Modele.GAM2)
```

Correction à la ?@sec-06072.

 Exercice**Exercice 2.** Réalisation d'un modèle GWR

```

library(sf)
library(spgwr)
load("data/chap02/DonneesLyon.Rdata")
# Ajout des coordonnées x et y
xy <- à compléter
LyonIris$X <- à compléter
LyonIris$Y <- à compléter
# Optimisation du nombre de voisins avec le CV
formule <- "PM25 ~ Pct0_14+Pct_65+Pct_Img+Pct_brevet+NivVieMed"
bwaCV.voisins <- gwr.sel(à compléter)
# Optimisation du nombre de voisins avec l'AIC
bwaCV.voisins <- gwr.sel(à compléter)
# Réalisation de la GWR
Modele.GWR <- gwr(à compléter)
# Affichage des résultats
Modele.GWR

```

Correction à la ?@sec-06073.

3 Modèles d'économétrie spatiale par panel

Dans ce chapitre, nous abordons une extension des modèles autorégressifs, soit les modèles spatiaux par panel qui permettent de modéliser des données spatiales longitudinales.

Objectif

Objectifs d'apprentissage visés dans ce chapitre

À la fin de ce chapitre, vous devriez être en mesure de :

- Comprendre les différentes formulations des modèles spatiaux par panel (SLPDM, SEPDM et SEPDM).
- Assimiler les principes fondamentaux de ces différents modèles.
- Identifier le modèle spatial par panel le plus approprié (SLPDM, SEPDM et SEPDM).
- Analyser les résultats produits par ces différents modèles.
- Mettre en pratique ces modèles spatiaux par panel dans R.

Package

Liste des *packages* utilisés dans ce chapitre

- Pour importer et manipuler des fichiers géographiques :
 - `sf` pour importer et manipuler des données vectorielles.
- Pour construire des cartes et des graphiques :
 - `tmap` pour construire des cartes thématiques.
 - `ggplot2` est un *package* pour construire des graphiques.
- Pour les régressions :
 - `spdep` pour construire des matrices spatiales et calculer des mesures d'autocorrélation spatiale.
 - `plm` pour construire des modèles de régression par panel.
 - `spplm` pour construire des modèles de régression spatiale par panel.

3.1 Bref retour sur les modèles en panel

3.2 Formulation des différents modèles spatiaux par panel

3.2.1 Description des différents modèles

3.2.2 Modèle SLPDM : autocorrélation sur la variable dépendante

3.2.3 Modèle SEPDM : autocorrélation sur le terme d'erreur

3.2.4 Modèle SEPDM : autocorrélation sur la variable dépendante et les variables indépendantes

3.3 Sélection du modèle spatial par panel le plus approprié

3.4 Mise en œuvre dans R

3.5 Quiz de révision

3.6 Exercices de révision

Exercice

Exercice 1. Calcul du centre moyen et de la distance standard pour les accidents
Complétez le code ci-dessous.

```
library(sf)
library(tmap)
```

Correction à la ?@sec-06031.

Exercice

Exercice 2. Calcul et cartographie de la densité des accidents dans un maillage irrégulier
Pour l'année 2021, complétez le code ci-dessous.

```
library(sf)
library(tmap)
```

Correction à la ?@sec-06032.

Exercice

Exercice 3. Calcul et cartographie de la densité des accidents dans un maillage régulier
Pour l'année 2021, complétez le code ci-dessous.

```
library(sf)
library(spatstat)
library(tmap)
```

Correction à la ?@sec-06033.

Partie 3. Régressions géographiquement pondérées

4 Régressions géographiquement pondérées classiques

La régression géographiquement pondérée (*geographically weighted regression* - **GWR**, en anglais) a été formalisée au milieu des années 1990 par Chris Brunsdon, Steward Fotheringham et Martin Charlton (1996), puis largement décrite dans un ouvrage de référence (Fotheringham, Brunsdon et Charlton 2003). Dans le cadre de ce chapitre, nous abordons uniquement la GWR classique qui s'applique à une variable dépendante continue (GWR gaussienne).

Objectif

Objectifs d'apprentissage visés dans ce chapitre

À la fin de ce chapitre, vous devriez être en mesure de :

- Comprendre pourquoi utiliser une GWR.
- Assimiler les principes fondamentaux d'une GWR classique (distribution gaussienne).
- Analyser les résultats produits par une GWR.
- Saisir que la GWR est un outil exploratoire intéressant, comprenant toutefois plusieurs limites et critiques importantes.
- Mettre en pratique une GWR dans R.

Package

Liste des *packages* utilisés dans ce chapitre

- Pour importer et manipuler des fichiers géographiques :
 - `sf` pour importer et manipuler des données vectorielles.
 - `dplyr` pour manipuler les données.
- Pour construire des cartes et des graphiques :
 - `tmap` pour les cartes.
 - `ggplot2` et `ggpubr` pour construire des graphiques.
 - `corrplot` et `GGally` pour créer des graphiques de matrices de corrélation.
- Pour construire des modèles de régressions :
 - `spgwr` pour construire des GWR gaussienne, logistique et Poisson.
 - `spdep` pour calculer le I de Moran sur les résidus des modèles.

4.1 Principe de base

4.1.1 Pourquoi recourir à une régression géographiquement pondérée?

Dans le chapitre 2, nous avons vu que les modèles d'économétrie spatiale visent à contrôler la **dépendance spatiale** d'un modèle de régression classique (MCO), afin d'améliorer l'estimation des coefficients de régression. L'objectif des modèles de régression géographiquement pondérée est différent : ils visent à analyser les variations spatiales de la relation entre la variable dépendante et les variables indépendantes. Autrement dit, les modèles GWR visent à explorer **l'instabilité spatiale du modèle MCO** afin d'analyser localement la relation entre la variable dépendante et les variables indépendantes. Pour une description détaillée en français de la GWR, consultez Apparicio *et al.* (2007).

4.1.2 Formulation de la GWR

Contrairement à la régression linéaire classique et aux modèles spatiaux autorégressifs qui produisent une équation pour l'ensemble du tableau de données, la GWR produit une équation pour chaque unité spatiale i et ainsi, des valeurs locales de R^2 , β_0 , β_k , t de Student, etc. La résolution de cette équation de régression locale est aussi basée sur la méthode des moindres carrés et sur une matrice de pondération $W(i)$ dont les valeurs décroissent en fonction de la distance séparant les unités i et j . Autrement dit, plus j est proche de i , plus sa pondération est élevée et donc plus son « rôle » dans la détermination de l'équation de régression locale de i est important.

De la sorte, la GWR est une extension de la régression linéaire multiple classique où (u_i, v_i) représente les coordonnées géographiques du centroïde de l'unité spatiale et où les paramètres β_0 et β_k peuvent varier dans l'espace (équation 4.1).

$$y_i = \beta_0(u_i, v_i) + \sum_{j=1}^k \beta_j(u_i, v_i)x_{ij} + \epsilon_i \quad (4.1)$$

avec :

- (u_i, v_i) , les coordonnées géographiques de l'unité spatiale i .
- y_i , la variable dépendante pour l'unité spatiale i .
- $\beta_0(u_i, v_i)$, la constante pour l'unité spatiale i aux coordonnées géographiques (u_i, v_i) .
- $\beta_j(u_i, v_i)$, le coefficient de régression pour la variable x_j (avec k variables indépendantes) pour l'unité spatiale i aux coordonnées géographiques (u_i, v_i) .
- x_{ij} , la valeur de la variable indépendante x_j pour l'unité spatiale i .
- ϵ_i , le terme d'erreur pour l'unité spatiale i .

Fotheringham *et al.* (2003) proposent deux principales fonctions *kernel* pour définir la pondération $W(i)$ dans le modèle GWR : une fonction gaussienne (équation 4.2) et une fonction bicarrée (équation 4.3) où d_{ij} représente la distance euclidienne entre les points i et j et b , le rayon de zone d'influence autour du point i (*bandwidth*). Il existe une différence fondamentale entre les deux : la fonction gaussienne accorde un poids non nul à tous les points de l'espace d'étude aussi loin soient-ils, tandis que la fonction bicarrée ne tient pas compte des points distants à plus de b mètres de i , tel qu'illustré à la figure 4.1 avec une valeur fixée à 5000 mètres en guise d'exemple.

$$w_{ij} = \exp \left(-\frac{1}{2} \left(\frac{d_{ij}}{b} \right)^2 \right) \quad (4.2)$$

$$w_{ij} = \left(1 - \left(\frac{d_{ij}}{b}\right)^2\right)^2 \text{ si } d_{ij} < b, \text{ sinon } w_{ij} = 0 \quad (4.3)$$

🔗 Aller plus loin

Autres fonctions Kernel pour la GWR

Outre les fonctions Kernel gaussienne et bicarrée, il est aussi possible d'utiliser des fonctions exponentielle (équation 4.4) et tricube (équation 4.5), et Boxcar (équation 4.6) implémentées dans les fonctions `bw.gw` et `gwr.basic` du package `GWmodel`.

$$w_{ij} = \exp\left(-\frac{d_{ij}}{b}\right) \quad (4.4)$$

$$w_{ij} = \left(1 - \left(\frac{d_{ij}}{b}\right)^3\right)^3 \text{ si } d_{ij} < b, \text{ sinon } w_{ij} = 0 \quad (4.5)$$

$$w_{ij} = 1 \text{ si } d_{ij} < b, \text{ sinon } w_{ij} = 0 \quad (4.6)$$




Figure 4.1: Fonctions kernel pour définir la matrice de pondération $W(i)$

Dans le modèle GWR, la valeur de b est soit fixée par la personne utilisatrice, soit optimisée avec la valeur de CV (*cross-validation*) ou celle de l'AIC. Notez qu'il est possible d'optimiser la taille de la zone d'influence à partir de la distance euclidienne ou du nombre de plus proches voisins.

4.1.3 Exemple applicatif de la GWR

Pour démontrer l'utilité de la GWR comme outil d'exploration de l'instabilité spatiale d'un modèle classique, nous utilisons le jeu de données sur Lyon (section 1.1.1). Le modèle de régression est construit avec comme variable dépendante le dioxyde d'azote (NO₂) et cinq variables sociodémographiques (section 1.1.1).

4.1.3.1 Résultats du modèle global

Les résultats de la régression linéaire multiple (modèle global) sont présentés au tableau 4.1. Les variables sociodémographiques (variables indépendantes) introduites dans le modèle expliquent 28,3 % de la variance du dioxyde d'azote (variable dépendante). La constante et tous les coefficients de régression du modèle sont significatifs ($p < 0,001$). Toutes choses étant égales par ailleurs, le pourcentage d'immigrants est associé positivement avec le dioxyde d'azote ($\beta = 0,283$), ce qui traduit une certaine iniquité environnementale pour ce groupe de population. À l'inverse, toutes les autres variables sont associées négativement.

Tableau 4.1: Résultats du modèle global (régression linéaire multiple)

Variable	Coef.	Erreur type	t	p
Constante	49,433	2,995	16,502	0,000
Pct0_14	-0,534	0,063	-8,461	0,000
Pct_65	-0,150	0,056	-2,674	0,008
Pct_Img	0,283	0,051	5,532	0,000
Pct_brevet	-0,240	0,037	-6,451	0,000
NivVieMed	-0,316	0,102	-3,107	0,002

Nombre d'observations = 506. R carré = 0,2832. R carré ajusté = 0,276.

L'objectif de la construction d'un modèle GWR est d'examiner l'instabilité spatiale de ce modèle, en analysant comment les associations observées dans le modèle global entre les cinq variables sociodémographiques et le dioxyde d'azote varient dans l'espace.

4.1.3.2 Résultats du modèle GWR

Définition de la zone d'influence

Puisque la superficie des 506 IRIS varie considérablement (avec de petits IRIS au centre de l'agglomération et de très grands IRIS en périphérie, figure 1.1), nous préférons optimiser la zone d'influence (b) avec le nombre de plus proches voisins et non la distance euclidienne avec l'approche *cross-validation*. Le résultat final de l'optimisation du nombre de plus proches voisins est de 92.

Comparaison des modèle global et GWR

L'analyse de variance entre les résidus des deux modèles démontre que le modèle GWR améliore de façon significative la capacité prédictive du modèle de régression globale (tableau 4.2). Les valeurs de R^2 passent d'ailleurs de 0,283 pour le modèle global à 0,784 pour le modèle GWR.

Tableau 4.2: Analyse de variance entre les modèles global et GWR

	dl	Somme des carrés	Moyenne des carrés	Valeur F
Résidus du modèle global	6,00	22 346,02		
Modèle GWR	101,13	15 581,60	154,08	
Résidus du modèle GWR	398,87	6 764,42	16,96	9,09

R carré du modèle global = 0,2832. R carré du modèle GWR = 0,7838.

Cartographie des valeurs de t

Afin de décrire les variations spatiales des associations entre les variables dépendantes et indépendantes, nous cartographions les valeurs de t pour chacune des cinq variables indépendantes (figure 4.2). Pour ce faire, nous utilisons les seuils de $\pm 1,96$, $2,58$ et $3,29$, indiquant des seuils de signification à 5 %, 1 % et 0,1 %. La cartographie des valeurs de t illustre clairement les variations spatiales de l'association entre les variables indépendantes et le dioxyde d'azote.

Premièrement, le modèle global avait révélé que toutes les variables indépendantes étaient significativement associées au seuil de 0,1 %, toutes choses étant égales par ailleurs. Or, localement certaines variables ne sont plus significatives au seuil de 5 % (valeurs de t comprises entre $-1,96$ et $1,96$), soit les IRIS en gris à la figure 4.2. Par exemple, le pourcentage d'enfants de moins de 15 ans est associé négativement au dioxyde d'azote uniquement dans la partie sud de l'agglomération.

Deuxièmement, le sens de la relation, c'est-à-dire du coefficient et de sa valeur de t associé, change pour certaines variables indépendantes. Cela est particulièrement le cas de la variable *médiane du niveau de vie* (milliers d'euros) qui affiche des valeurs positives dans le centre-ville, mais des valeurs négatives en périphérie. Autrement dit, une hausse du niveau de vie des résidents est associée à une réduction du dioxyde d'azote dans les quartiers et municipalités périphériques de l'agglomération, mais à une augmentation dans les quartiers centraux.

Cartographie du nombre de variables significative et de la variable plus significatives

Pour compléter l'exploration des résultats de la GWR, il est possible de répondre à deux dernières questions avec de nouvelles analyses cartographiques (figure 4.3) :

- Quelle est la variable indépendante la plus significative localement ?
- Comment de variables indépendantes sont localement significatives (au seuil de 5 %) ?

Les deux variables les plus significatives localement sont celles relatives au niveau de vie à la population de moins de 15 ans (toutes deux 124 IRIS). Aussi, 159 modèles locaux ne présentent aucune variable significative au seuil retenu.

4.2 Mise en œuvre et analyse dans R

Il existe deux principaux *packages* pour mettre en œuvre des modèles GWR, soit `spgwr` (Bivand et Yu 2023) et `GWmodel` (Isabella Gollini et al. 2015; Binbin Lu et al. 2014). La construction d'un modèle GWR comprend les étapes suivantes :

1. Sélection de la taille de la zone d'influence (*bandwidth*) optimale.
2. Réalisation de la GWR avec la taille de la zone d'influence optimale.
3. Comparaison des modèles MCO et GWR.
4. Cartographie des résultats du modèle GWR (R^2 , coefficients, valeurs de t , etc.).




Figure 4.2: Cartographie des valeurs de t : moins de 15 ans (%)




Figure 4.3: Variables indépendantes significatives du modèle GWR

4.2.1 GWR avec le package `spgwr`

4.2.1.1 Définition de la taille de la zone d'influence

La sélection de la taille de la zone d'influence optimale est réalisée avec la fonction `gwr.sel` pour laquelle :

- le paramètre `gweight` permet de spécifier une fonction *kernel* gaussienne (`gwr.gauss`) ou bicarrée (`gwr.gauss`).
- le paramètre `adapt` permet de spécifier si vous optimisez le nombre de plus proches voisins (`adapt=TRUE`) ou la distance (`adapt=FALSE`).

```
## Chargement des packages et des données
library(sf)
library(tmap)
library(spgwr)
load("data/Lyon.Rdata")
## Ajout des coordonnées X et Y dans LyonIris
xy <- st_coordinates(st_centroid(LyonIris))
LyonIris$X <- xy[,1]
LyonIris$Y <- xy[,2]
## Optimisation du nombre de voisins avec le CV
bwCV.voisins <- gwr.sel(N02 ~ Pct0_14+Pct_65+Pct_Img+Pct_brevet+NivVieMed,
                        data = LyonIris,
```

```

method = "cv",          # Méthode cv ou AIC
gweight=gwr.bisquare,   # gwr.gauss ou gwr.bisquare
adapt=TRUE,
verbose = FALSE,
RMSE = TRUE,
longlat = FALSE,
coords=cbind(LyonIris$X,LyonIris$Y))

## Optimisation du nombre de voisins avec l'AIC
bwaAIC.voisins <- gwr.sel(N02 ~ Pct0_14+Pct_65+Pct_Img+Pct_brevet+NivVieMed,
  data = LyonIris,
  method = "AIC",        # Méthode cv ou AIC
  gweight=gwr.bisquare,  # gwr.gauss ou gwr.bisquare
  adapt=TRUE,            # adaptatif
  verbose = FALSE,
  RMSE = TRUE,
  longlat = FALSE,
  coords=cbind(LyonIris$X,LyonIris$Y))

## Optimisation de la distance avec le CV
bwnaCV.dist <- gwr.sel(N02 ~ Pct0_14+Pct_65+Pct_Img+Pct_brevet+NivVieMed,
  data = LyonIris,
  method = "cv",        # méthode cv ou AIC
  gweight=gwr.Gauss,    # gwr.gauss ou gwr.bisquare
  adapt=FALSE,          # non adaptatif
  verbose = FALSE,
  RMSE = TRUE,
  longlat = FALSE,
  coords=cbind(LyonIris$X,LyonIris$Y))

## Optimisation de la distance avec l'AIC
bwnaAIC.dist <- gwr.sel(N02 ~ Pct0_14+Pct_65+Pct_Img+Pct_brevet+NivVieMed,
  data = LyonIris,
  method = "AIC",       # méthode cv ou AIC
  gweight=gwr.Gauss,    # gwr.gauss ou gwr.bisquare
  adapt=FALSE,          # non adaptatif
  RMSE = TRUE,
  verbose = FALSE,
  longlat = FALSE,
  coords=cbind(LyonIris$X,LyonIris$Y))

## Affichage des résultats d'optimisation
cat("Sélection de la taille de la zone optimale (bandwidth)",
  "\n avec le nombre de plus proches voisins :",
  "\n  CV =", round(bwCV.voisins,4), "nombre de voisins =",
  round(bwCV.voisins*nrow(LyonIris)),
  "\n  AIC =", round(bwaAIC.voisins,4), "nombre de voisins =",
  round(bwaAIC.voisins*nrow(LyonIris)),
  "\nSélection de la taille de la zone optimale (bandwidth) avec la distance :",
  "\n  CV =", round(bwnaCV.dist, 0), "mètres",

```

```
"\n  AIC =", round(bwnaAIC.dist, 0), "mètres")
```

Sélection de la taille de la zone optimale (bandwidth)

avec le nombre de plus proches voisins :

CV = 0.1818 nombre de voisins = 92

AIC = 0.1067 nombre de voisins = 54

Sélection de la taille de la zone optimale (bandwidth) avec la distance :

CV = 1315 mètres

AIC = 1662 mètres

Les résultats ci-dessus montrent que le nombre de plus proches voisins pourrait être de 92 selon l'approche *cross-validation* et de 54 selon la méthode basée sur l'AIC. Si la valeur de b est basée sur la distance, elle serait alors optimale à 1315 et 1662 mètres selon les deux méthodes.

4.2.1.2 Réalisation de la GWR

Avec la fonction `gwr`, nous estimons un modèle GWR avec un *kernel* bicarré et un nombre optimisé de plus voisins selon la méthode CV, soit 92.

```
# Modèle global : régression linéaire multiple
Modele.Global <- lm(N02 ~ Pct0_14 + Pct_65 + Pct_Img + Pct_brevet + NivVieMed, data = LyonIris)
# Modèle GWR
Modele.GWR <- gwr(N02 ~ Pct0_14+Pct_65+Pct_Img+Pct_brevet+NivVieMed,
  data = LyonIris,
  adapt=bwCV.voisins,
  gweight=gwr.bisquare,
  hatmatrix=TRUE,
  se.fit=TRUE,
  coords=cbind(LyonIris$X,LyonIris$Y),
  longlat=FALSE)
```

Le code ci-dessous permet de renvoyer les statistiques univariées des coefficients des 506 régressions locales, réalisées pour chacune des 506 entités spatiales (IRIS), et les statistiques d'ajustement du modèle du modèle GWR (AIC, R^2 quasi-global, etc.).

```
Modele.GWR
```

Call:

```
gwr(formula = N02 ~ Pct0_14 + Pct_65 + Pct_Img + Pct_brevet +
  NivVieMed, data = LyonIris, coords = cbind(LyonIris$X, LyonIris$Y),
  gweight = gwr.bisquare, adapt = bwCV.voisins, hatmatrix = TRUE,
  longlat = FALSE, se.fit = TRUE)
Kernel function: gwr.bisquare
Adaptive quantile: 0.1818192 (about 92 of 506 data points)
```

Summary of GWR coefficient estimates at data points:

	Min.	1st Qu.	Median	3rd Qu.	Max.	Global
X.Intercept.	12.429518	30.249511	38.619342	48.038863	60.098584	49.4330
Pct0_14	-1.094802	-0.360556	-0.215643	-0.047687	0.382801	-0.5335
Pct_65	-0.715331	-0.158253	-0.031353	0.076086	0.464992	-0.1505
Pct_Img	-0.331892	-0.049146	0.077177	0.240755	0.670433	0.2829
Pct_brevet	-0.655221	-0.221655	-0.084954	0.047835	0.598456	-0.2400
NivVieMed	-1.140895	-0.560649	-0.214717	0.193768	1.311228	-0.3162

Number of data points: 506
 Effective number of parameters (residual: 2traceS - traceS'S): 107.1278
 Effective degrees of freedom (residual: 2traceS - traceS'S): 398.8722
 Sigma (residual: 2traceS - traceS'S): 4.118116
 Effective number of parameters (model: traceS): 81.53263
 Effective degrees of freedom (model: traceS): 424.4674
 Sigma (model: traceS): 3.992025
 Sigma (ML): 3.656286
 AICc (GWR p. 61, eq. 2.33; p. 96, eq. 4.21): 2945.674
 AIC (GWR p. 96, eq. 4.22): 2829.504
 Residual sum of squares: 6764.424
 Quasi-global R2: 0.783008

4.2.1.3 Comparaison des modèles MCO et GWR

Le R^2 du modèle GWR est bien supérieur à celui du modèle classique MCO (0,783 contre 0,283).

```
R2.global <- summary(Modele.Global)$r.squared
rss <- sum((Modele.GWR$lm$y - Modele.GWR$SDF$pred)^2)
tss <- sum((Modele.GWR$lm$y - mean(Modele.GWR$SDF$pred))^2)
R2.GWRquasiglobal <- 1 - (rss / tss)
cat("R2 global (LM) = ", round(R2.global, 3),
    "\nR2 quasi-global (GWR) : ", round(R2.GWRquasiglobal, 3))
```

R2 global (LM) = 0.283

R2 quasi-global (GWR) : 0.784

Fotheringham *et al.* (2003) proposent plusieurs tests pour comparer les modèles GWR et classique qui sont implémentés dans le *package* *spgwr* : fonctions `BFC99.gwr.test(Modele.GWR)`, `BFC02.gwr.test(Modele.GWR)`, `LMZ.F1GWR.test(Modele.GWR)`, `LMZ.F2GWR.test(Modele.GWR)`. Si les valeurs de p de ces tests sont inférieures à 0,05, alors le modèle GWR améliore de façon significative la capacité prédictive du modèle de régression globale, ce que confirment les résultats ci-dessous.

```
anova(Modele.GWR)
```

Analysis of Variance Table

	Df	Sum Sq	Mean Sq	F value
OLS Residuals	6.00	22346.0		
GWR Improvement	101.13	15581.6	154.078	
GWR Residuals	398.87	6764.4	16.959	9.0854

`BFC99.gwr.test(Modele.GWR)`

Brunsdon, Fotheringham & Charlton (1999) ANOVA

data: Modele.GWR
 F = 9.0854, df1 = 350.93, df2 = 430.81, p-value < 2.2e-16
 alternative hypothesis: greater
 sample estimates:
 SS GWR improvement SS GWR residuals
 15581.596 6764.424

`BFC02.gwr.test(Modele.GWR)`

Brunsdon, Fotheringham & Charlton (2002, pp. 91-2) ANOVA

data: Modele.GWR
 F = 3.3035, df1 = 500.00, df2 = 398.87, p-value < 2.2e-16
 alternative hypothesis: greater
 sample estimates:
 SS OLS residuals SS GWR residuals
 22346.021 6764.424

`LMZ.F1GWR.test(Modele.GWR)`

Leung et al. (2000) F(1) test

data: Modele.GWR
 F = 0.37946, df1 = 430.81, df2 = 500.00, p-value < 2.2e-16
 alternative hypothesis: less
 sample estimates:
 SS OLS residuals SS GWR residuals
 22346.021 6764.424

`LMZ.F2GWR.test(Modele.GWR)`

Leung et al. (2000) F(2) test

```
data: Modele.GWR
F = 3.4476, df1 = 142.92, df2 = 500.00, p-value < 2.2e-16
alternative hypothesis: greater
sample estimates:
  SS OLS residuals SS GWR improvement
      22346.02      15581.60
```

Un autre test (`LMZ.F3GWR.test`) permet de répondre à la question suivante : est-ce que les coefficients de régression du modèle GWR varient spatialement de façon significative? Les résultats ci-dessous démontrent que c'est le cas pour toutes les variables indépendantes et la constante ($p < 0,001$).

```
LMZ.F3GWR.test(Modele.GWR)
```

Leung et al. (2000) F(3) test

	F statistic	Numerator d.f.	Denominator d.f.	Pr(>)
(Intercept)	2.2771	134.3880	430.81	1.629e-10 ***
Pct0_14	2.7767	141.7244	430.81	5.636e-16 ***
Pct_65	2.0918	169.0472	430.81	8.399e-10 ***
Pct_Img	1.9486	106.4400	430.81	1.550e-06 ***
Pct_brevet	2.4445	121.2830	430.81	1.629e-11 ***
NivVieMed	3.6926	138.8118	430.81	< 2.2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Pour comparer **la dépendance spatiale** des deux modèles (MCO versus GWR), nous calculons le I de Moran sur leurs résidus avec une matrice de contiguïté standardisée selon le partage d'un segment (*Rook*). Avec une valeur du I de Moran de 0,587 ($p < 0,001$), les résidus du modèle global (MCO) sont fortement autocorrélés spatialement, traduisant ainsi un problème de dépendance spatiale du modèle. Bien qu'elle soit toujours significative, l'autocorrélation spatiale des résidus du modèle GWR est bien plus faible (0,275, $p < 0,001$). La cartographie des résidus des deux modèles à la figure 4.4 corrobore ces résultats.

```
library(spdep)
## Résidus des modèles global (MCO) et GWR
LyonIris$MCO.Residus <- Modele.Global$residuals
LyonIris$GWR.Residus <- Modele.GWR$SDF$pred - Modele.GWR$lm$y
## Matrice de contiguïté selon le partage d'un nœud
Rook <- poly2nb(LyonIris, queen=TRUE)
W.Rook <- nb2listw(Rook, zero.policy=TRUE, style = "W")
# I de Moran sur les résidus du modèle global (MCO)
moran.test(LyonIris$MCO.Residus, W.Rook, randomisation = FALSE)
```

Moran I test under normality

```
data: LyonIris$MCO.Residus
weights: W.Rook
```

```
Moran I statistic standard deviate = 21.275, p-value < 2.2e-16
alternative hypothesis: greater
sample estimates:
```

Moran I statistic	Expectation	Variance
0.5775768402	-0.0019801980	0.0007420591

```
# I de Moran sur les résidus du modèle GWR (MCO)
moran.test(LyonIris$GWR.Residus, W.Rook, randomisation = FALSE)
```

Moran I test under normality

```
data: LyonIris$GWR.Residus
weights: W.Rook
```

```
Moran I statistic standard deviate = 10.171, p-value < 2.2e-16
alternative hypothesis: greater
sample estimates:
```

Moran I statistic	Expectation	Variance
0.2750946577	-0.0019801980	0.0007420591

```
## Cartographie des résidus du modèle MCO
tmap_mode("plot")
Carte1 <- tm_shape(LyonIris)+
  tm_borders(col="gray25", lwd=.5)+
  tm_fill(col="MCO.Residus", n = 6, style = "pretty",
    legend.format = list(text.separator = "à",
      decimal.mark = ","),
    midpoint = 0,
    palette = "-RdBu",
    title = "MCO") +
  tm_layout(frame=FALSE)
## Cartographie des résidus du modèle GWR
Carte2 <- tm_shape(LyonIris)+
  tm_borders(col="gray25", lwd=.5)+
  tm_fill(col="GWR.Residus", n = 6, style = "pretty",
    legend.format = list(text.separator = "à",
      decimal.mark = ","),
    midpoint = 0,
    palette = "-RdBu",
```

```

title = "GWR") +
tm_layout(frame=FALSE) +
tm_scale_bar(breaks = c(0,5))
tmap_arrange(Carte1, Carte2, nrow = 1)

```




Figure 4.4: Cartographie des résidus des modèles MCO et GWR

4.2.1.4 Cartographie des résultats du modèle GWR

Dans un premier temps, nous ajoutons les valeurs locales des R^2 , des coefficients de régression et des valeurs de t dans la couche `sf`. Notez que les résultats locaux de la GWR sont stockés dans l'objet `Modele.GWR$SDF`.

```

## Récupération du R carré local
LyonIris$GWR.R2 <- Modele.GWR$SDF$localR2
## Récupération des coefficients de régression et calcul des valeurs de t locales
names(Modele.GWR$SDF)

```

```

[1] "sum.w"           "(Intercept)"      "Pct0_14"
[4] "Pct_65"          "Pct_Img"          "Pct_brevet"
[7] "NivVieMed"       "(Intercept)_se"   "Pct0_14_se"
[10] "Pct_65_se"       "Pct_Img_se"       "Pct_brevet_se"
[13] "NivVieMed_se"    "gwr.e"            "pred"

```

```
[16] "pred.se"          "localR2"          "(Intercept)_se_EDF"
[19] "Pct0_14_se_EDF"   "Pct_65_se_EDF"    "Pct_Img_se_EDF"
[22] "Pct_brevet_se_EDF" "NivVieMed_se_EDF" "pred.se"
```

```
VarsIndep <- c("Pct0_14", "Pct_65", "Pct_Img", "Pct_brevet", "NivVieMed")
for(e in VarsIndep){
  # Nom des nouvelles variables
  var.coef <- paste0("GWR.", "B_", e)
  var.t     <- paste0("GWR.", "T_", e)
  # Récupération des coefficients pour les variables indépendantes
  LyonIris[[var.coef]] <- Modele.GWR$SDF[[e]]
  # Calcul des valeurs de t pour les variables indépendantes
  LyonIris[[var.t]]    <- Modele.GWR$SDF[[e]] / Modele.GWR$SDF[[paste0(e, "_se")]]
}
```

Cartographie et analyse des R^2 locaux

Les deux lignes de code ci-dessous permettent d'obtenir un résumé sommaire des statistiques descriptives (minimum, quartiles 1 à 3, moyenne et maximum) des valeurs locales de R^2 , mais aussi de constater qu'elles varient de 0,19 à 0,74 pour 95 % des 506 observations (IRIS).

```
summary(LyonIris$GWR.R2)
```

```
      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
0.0888  0.4205  0.5281  0.5081  0.6322  0.7774
```

```
round(quantile(LyonIris$GWR.R2, probs = c(0.025, 0.975)), 4)
```

```
      2.5% 97.5%
0.1876 0.7390
```

Le code ci-dessous permet ensuite de cartographier les R^2 locaux de la GWR (figure 4.5).

```
library(tmap)
# Paramètres pour la légende
legende.parametres <- list(text.separator = "à",
                           decimal.mark = ",")

tm_shape(LyonIris)+
  tm_borders(col="gray25", lwd=.5)+
  tm_fill(col="GWR.R2",
          palette="YlOrBr",
          n=5, style="quantile",
          legend.format = legende.parametres,
```

```
    title = "R2 locaux")+  
tm_layout(frame=FALSE)+  
tm_scale_bar(breaks=c(0,5))
```




Figure 4.5: Cartographie des R carrés locaux de la GWR

Cartographie des coefficients de régression locaux

Le code ci-dessous permet ensuite de cartographier les coefficients locaux de la GWR (figure 4.6).

```
# Paramètres pour la légende
legende.parametres <- list(text.separator = "à",
                           decimal.mark = ",",
                           big.mark = " ")

Carte1 <- tm_shape(LyonIris)+ tm_borders(col="gray25", lwd=.5)+
  tm_fill(col="GWR.B_Pct0_14", palette="YlOrBr", n=4, style="pretty",
          legend.format = legende.parametres,
          title = "Moins de 15 ans (%)")+
  tm_layout(frame=FALSE, legend.outside = TRUE)

Carte2 <- tm_shape(LyonIris)+ tm_borders(col="gray25", lwd=.5)+
  tm_fill(col="GWR.B_Pct_65", palette="YlOrBr", n=4, style="pretty",
          legend.format = legende.parametres,
          title = "65 ans et plus (%)")+
  tm_layout(frame=FALSE, legend.outside = TRUE)

Carte3 <- tm_shape(LyonIris)+ tm_borders(col="gray25", lwd=.5)+
  tm_fill(col="GWR.B_Pct_Img", palette="YlOrBr", n=4, style="pretty",
          legend.format = legende.parametres,
          title = "Immigrants (%)")+
  tm_layout(frame=FALSE, legend.outside = TRUE)

Carte4 <- tm_shape(LyonIris)+ tm_borders(col="gray25", lwd=.5)+
  tm_fill(col="GWR.B_Pct_brevet", palette="YlOrBr", n=4, style="pretty",
          legend.format = legende.parametres,
          title = "Faible scolarité (%)")+
  tm_layout(frame=FALSE, legend.outside = TRUE)

Carte5 <- tm_shape(LyonIris)+ tm_borders(col="gray25", lwd=.5)+
  tm_fill(col="GWR.B_NivVieMed", palette="YlOrBr", n=4, style="pretty",
          legend.format = legende.parametres,
          title = "Niveau de vie (€1000)")+
  tm_layout(frame=FALSE, legend.outside = TRUE)+
  tm_scale_bar(breaks=c(0,5))

tmap_arrange(Carte1, Carte2, Carte3, Carte4, Carte5, ncol = 2, nrow=3)
```




Figure 4.6: Cartographie des coefficients de régression de la GWR

Cartographie des valeurs de t locales

Pour cartographier les valeurs de t , nous utilisons les seuils de $\pm 1,96$, $2,58$ et $3,29$, indiquant des seuils de signification à 5 %, 1 % et 0,1 % (figure 4.7).

```
# Paramètres pour la légende
legende.parametres <- list(text.separator = "à",
                             text.less.than = "Moins de",
                             text.or.more = "et plus",
                             decimal.mark = ",",
                             big.mark = " ")

classes.intervalles = c(-Inf, -3.29, -2.58, -1.96, 1.96, 2.58, 3.29, Inf)
Cartel <- tm_shape(LyonIris) + tm_borders(col="gray25", lwd=.5) +
  tm_fill(col="GWR.T_Pct0_14", palette="-RdBu",
          midpoint = NA,
```

```

        breaks = classes.intervalles,
        legend.format = legende.parametres,
        title = "Moins de 15 ans (%)")+
    tm_layout(frame=FALSE, legend.outside = TRUE)

Carte2 <- tm_shape(LyonIris)+ tm_borders(col="gray25", lwd=.5)+
    tm_fill(col="GWR.T_Pct_65", palette="-RdBu",
        midpoint = NA,
        breaks = classes.intervalles,
        legend.format = legende.parametres,
        title = "65 ans et plus (%)")+
    tm_layout(frame=FALSE, legend.outside = TRUE)

Carte3 <- tm_shape(LyonIris)+ tm_borders(col="gray25", lwd=.5)+
    tm_fill(col="GWR.T_Pct_Img", palette="-RdBu",
        midpoint = NA,
        breaks = classes.intervalles,
        legend.format = legende.parametres,
        title = "Immigrants (%)")+
    tm_layout(frame=FALSE, legend.outside = TRUE)

Carte4 <- tm_shape(LyonIris)+ tm_borders(col="gray25", lwd=.5)+
    tm_fill(col="GWR.T_Pct_brevet", palette="-RdBu",
        midpoint = NA,
        breaks = classes.intervalles,
        legend.format = legende.parametres,
        title = "Faible scolarité (%)")+
    tm_layout(frame=FALSE, legend.outside = TRUE)

Carte5 <- tm_shape(LyonIris)+ tm_borders(col="gray25", lwd=.5)+
    tm_fill(col="GWR.T_NivVieMed", palette="-RdBu",
        midpoint = NA,
        breaks = classes.intervalles,
        legend.format = legende.parametres,
        title = "Niveau de vie (€1000)")+
    tm_layout(frame=FALSE, legend.outside = TRUE)+
    tm_scale_bar(breaks=c(0,5))

tmap_arrange(Carte1, Carte2, Carte3, Carte4, Carte5, ncol = 2, nrow=3)

```




Figure 4.7: Cartographie des valeurs de t de la GWR

Cartographie du nombre de variables significatives

Nous pouvons aussi cartographier le nombre de variables localement significatives aux seuils de 5 % et 1 %.

```
## Identifier la variable plus significative avec les valeurs de t
VarsT <- paste0("GWR.T_", c("Pct0_14", "Pct_65", "Pct_Img", "Pct_brevet", "NivVieMed"))
Lyon.df <- st_drop_geometry(LyonIris)
Lyon.df <- abs(Lyon.df[,VarsT])
PlusSign <- VarsT[apply(Lyon.df[VarsT], 1, which.max)]
PlusSign <- substr(PlusSign, 7, nchar(PlusSign))
MaxAbsTvalue <- apply(Lyon.df[VarsT], 1, max)
PlusSign <- ifelse(MaxAbsTvalue < 1.96, "Aucune", PlusSign)
## Nombre de variables significatives au seuil de 5%, soit abs(t) = 1,96
LyonIris$NbSignif_1.96 <- as.factor(rowSums(Lyon.df > 1.96))
LyonIris$NbSignif_2.58 <- as.factor(rowSums(Lyon.df > 2.58))
LyonIris$PlusSign <- as.factor(PlusSign)
```

```
## Cartographie
Carte1 <- tm_shape(LyonIris)+ tm_borders(col="gray25", lwd=.5)+
  tm_fill(col="NbSignif_1.96", palette="Reds",
    title = "Sign. au seuil de 5%")+
  tm_layout(frame=FALSE)+ tm_scale_bar(breaks=c(0,5))
Carte2 <- tm_shape(LyonIris)+ tm_borders(col="gray25", lwd=.5)+
  tm_fill(col="NbSignif_2.58", palette="Reds",
    title = "Sign. au seuil de 1%")+
  tm_layout(frame=FALSE)
tmap_arrange(Carte1, Carte2, ncol=2, nrow=1)
```




Figure 4.8: Nombre de variables significatives aux seuils de 5% et 1%

Cartographie de la variable la plus significative avec la valeur de t

Finalement, le code ci-dessous permet de repérer la variable la plus significative au seuil de 5 %, c'est-à-dire avec la plus forte valeur absolue pour la valeur de t .

```
tm_shape(LyonIris)+ tm_borders(col="gray25", lwd=.5)+
  tm_fill(col="PlusSign", palette="Set1",
    title = "Variable la plus significative")+
  tm_layout(frame=FALSE)+ tm_scale_bar(breaks=c(0,5))
```




Figure 4.9: Variable indépendante la plus significative au seuil de 5 %

4.2.2 GWR avec le package `GWmodel`

La construction d'une régression GWR est certainement plus simple (moins verbeuse) avec les fonctions `bw.gwr` et `gwr.basic` du package `GWmodel`.

4.2.2.1 Définition de la taille de la zone d'influence

```
library(GWmodel)
load("data/Lyon.Rdata")
# Construction de la matrice de distance
xy <- st_coordinates(st_centroid(LyonIris))
MatriceDistance <- gw.dist(dp.locat=xy, p = 2, longlat=FALSE)
## Optimisation du nombre de voisins avec le CV
bwCV.voisins <- bw.gwr(N02 ~ Pct0_14+Pct_65+Pct_Img+Pct_brevet+NivVieMed,
                      data = LyonIris,
                      dMat = MatriceDistance,
                      approach="CV",
                      kernel="bisquare",
                      adaptive=TRUE,
                      longlat=FALSE)
```

```
Adaptive bandwidth: 320 CV score: 17072.1
Adaptive bandwidth: 206 CV score: 14142.57
Adaptive bandwidth: 134 CV score: 12329.97
Adaptive bandwidth: 91 CV score: 11919.32
Adaptive bandwidth: 63 CV score: 12156.26
Adaptive bandwidth: 107 CV score: 11981.63
Adaptive bandwidth: 79 CV score: 12001.41
Adaptive bandwidth: 96 CV score: 11900.81
Adaptive bandwidth: 101 CV score: 11912.07
Adaptive bandwidth: 94 CV score: 11919.6
Adaptive bandwidth: 98 CV score: 11911.68
Adaptive bandwidth: 95 CV score: 11911.87
Adaptive bandwidth: 97 CV score: 11899.93
Adaptive bandwidth: 97 CV score: 11899.93
```

```
## Optimisation du nombre de voisins avec l'AIC
bwAIC.voisins <- bw.gwr(N02 ~ Pct0_14+Pct_65+Pct_Img+Pct_brevet+NivVieMed,
                      data = LyonIris,
                      dMat = MatriceDistance,
                      approach="AIC",
                      kernel="bisquare",
                      adaptive=TRUE,
                      longlat=FALSE)
```

```
Adaptive bandwidth (number of nearest neighbours): 320 AICc value: 3181.763
Adaptive bandwidth (number of nearest neighbours): 206 AICc value: 3072.458
Adaptive bandwidth (number of nearest neighbours): 134 AICc value: 2989.605
Adaptive bandwidth (number of nearest neighbours): 91 AICc value: 2943.187
Adaptive bandwidth (number of nearest neighbours): 63 AICc value: 2925.002
Adaptive bandwidth (number of nearest neighbours): 47 AICc value: 2927.612
Adaptive bandwidth (number of nearest neighbours): 74 AICc value: 2929.903
Adaptive bandwidth (number of nearest neighbours): 57 AICc value: 2922.621
Adaptive bandwidth (number of nearest neighbours): 52 AICc value: 2922.879
Adaptive bandwidth (number of nearest neighbours): 58 AICc value: 2923.89
Adaptive bandwidth (number of nearest neighbours): 54 AICc value: 2922.612
Adaptive bandwidth (number of nearest neighbours): 54 AICc value: 2922.612
```

```
## Optimisation de la distance avec le CV
bwnCV.dist <- bw.gwr(NO2 ~ Pct0_14+Pct_65+Pct_Img+Pct_brevet+NivVieMed,
  data = LyonIris,
  dMat = MatriceDistance,
  approach="CV",
  kernel="gaussian",
  adaptive=FALSE,
  longlat=FALSE)
```

```
Fixed bandwidth: 22632.98 CV score: 23240.62
Fixed bandwidth: 13990.75 CV score: 22942.89
Fixed bandwidth: 8649.556 CV score: 21987.02
Fixed bandwidth: 5348.517 CV score: 19330.61
Fixed bandwidth: 3308.362 CV score: 15656.55
Fixed bandwidth: 2047.478 CV score: 13534
Fixed bandwidth: 1268.208 CV score: 12883.62
Fixed bandwidth: 786.5929 CV score: 69868.32
Fixed bandwidth: 1565.863 CV score: 13058.8
Fixed bandwidth: 1084.247 CV score: 13320.38
Fixed bandwidth: 1381.902 CV score: 12891.23
Fixed bandwidth: 1197.941 CV score: 12968.27
Fixed bandwidth: 1311.635 CV score: 12869.97
Fixed bandwidth: 1338.475 CV score: 12872.81
Fixed bandwidth: 1295.047 CV score: 12872.27
Fixed bandwidth: 1321.887 CV score: 12870.16
Fixed bandwidth: 1305.299 CV score: 12870.46
Fixed bandwidth: 1315.551 CV score: 12869.91
Fixed bandwidth: 1317.971 CV score: 12869.95
Fixed bandwidth: 1314.055 CV score: 12869.91
Fixed bandwidth: 1316.475 CV score: 12869.92
Fixed bandwidth: 1314.98 CV score: 12869.9
Fixed bandwidth: 1314.627 CV score: 12869.91
Fixed bandwidth: 1315.198 CV score: 12869.9
```

```
## Optimisation de la distance avec l'AIC
bwAIC.dist <- bw.gwr(NO2 ~ Pct0_14+Pct_65+Pct_Img+Pct_brevet+NivVieMed,
  data = LyonIris,
  dMat = MatriceDistance,
  approach="AIC",
  kernel="gaussian",
  adaptive=FALSE,
  longlat=FALSE)
```

```
Fixed bandwidth: 22632.98 AICc value: 3362.597
Fixed bandwidth: 13990.75 AICc value: 3354.75
Fixed bandwidth: 8649.556 AICc value: 3328.284
Fixed bandwidth: 5348.517 AICc value: 3241.508
Fixed bandwidth: 3308.362 AICc value: 3114.667
Fixed bandwidth: 2047.478 AICc value: 3043.093
Fixed bandwidth: 1268.208 AICc value: 3050.841
Fixed bandwidth: 2529.093 AICc value: 3065.054
Fixed bandwidth: 1749.823 AICc value: 3036.6
Fixed bandwidth: 1565.863 AICc value: 3036.749
Fixed bandwidth: 1863.517 AICc value: 3038.25
Fixed bandwidth: 1679.556 AICc value: 3036.195
Fixed bandwidth: 1636.129 AICc value: 3036.214
Fixed bandwidth: 1706.396 AICc value: 3036.289
Fixed bandwidth: 1662.969 AICc value: 3036.176
Fixed bandwidth: 1652.717 AICc value: 3036.181
Fixed bandwidth: 1669.305 AICc value: 3036.18
Fixed bandwidth: 1659.053 AICc value: 3036.177
Fixed bandwidth: 1665.389 AICc value: 3036.177
Fixed bandwidth: 1661.473 AICc value: 3036.176
Fixed bandwidth: 1660.549 AICc value: 3036.176
```

```
## Affichage des résultats d'optimisation
cat("Sélection de la taille de la zone optimale (bandwidth)",
  "\n avec le nombre de plus proches voisins :",
  "\n CV =", round(bwCV.voisins,4), "nombre de voisins =", round(bwCV.voisins*nrow(LyonIris)),
  "\n AIC =", round(bwAIC.voisins,4), "nombre de voisins =", round(bwAIC.voisins*nrow(LyonIris)),
  "\nSélection de la taille de la zone optimale (bandwidth) avec la distance :",
  "\n CV =", round(bwnCV.dist, 0), "mètres",
  "\n AIC =", round(bwAIC.dist, 0), "mètres")
```

Sélection de la taille de la zone optimale (bandwidth)
 avec le nombre de plus proches voisins :
 CV = 97 nombre de voisins = 49082
 AIC = 54 nombre de voisins = 27324
 Sélection de la taille de la zone optimale (bandwidth) avec la distance :

CV = 1315 mètres
AIC = 1661 mètres

4.2.2.2 Réalisation de la GWR

Comparativement à la fonction `gwr` du *package* `spgwr`, `gwr.basic` du *package* `GWmodel` offre l'avantage de fournir l'ensemble des résultats :

- Ceux de la régression linéaire multiple (modèle global).
- Un sommaire statistique des coefficients de régression de la GWR.
- Les statistiques de la qualité d'ajustement du modèle (AIC, AICc, R^2 , R^2 ajusté).
- Les tests pour comparer les modèles global et GWR (tests F1, F2).
- Le test F3 pour vérifier si les coefficients de régression varient ou non spatialement de façon significative.

```
# Calcul de la GWR
Modele.GWR <- gwr.basic(N02 ~ Pct0_14+Pct_65+Pct_Img+Pct_brevet+NivVieMed,
                        data = LyonIris,
                        dMat = MatriceDistance, # Matrice de distances
                        bw = bwCV.voisins,      # Zone d'influence
                        kernel = "bisquare",    # Gaussien ou bicarrée
                        adaptive=TRUE,         # Nombre de voisins (TRUE) ou distance (FALSE)
                        F123.test = TRUE,      # Tests F123
                        longlat=FALSE)

Modele.GWR
```

```
*****
*                               Package    GWmodel                               *
*****
Program starts at: 2025-01-24 01:05:34.557441
Call:
gwr.basic(formula = N02 ~ Pct0_14 + Pct_65 + Pct_Img + Pct_brevet +
  NivVieMed, data = LyonIris, bw = bwCV.voisins, kernel = "bisquare",
  adaptive = TRUE, longlat = FALSE, dMat = MatriceDistance,
  F123.test = TRUE)

Dependent (y) variable:  N02
Independent variables:  Pct0_14 Pct_65 Pct_Img Pct_brevet NivVieMed
Number of data points: 506
*****
*                               Results of Global Regression                               *
*****

Call:
lm(formula = formula, data = data)
```

```

Residuals:
    Min       1Q   Median       3Q      Max
-27.733  -4.457  -0.499   3.507  29.160

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  49.43296    2.99550   16.502 < 2e-16 ***
Pct0_14      -0.53352    0.06305   -8.461 2.94e-16 ***
Pct_65       -0.15047    0.05627   -2.674 0.00774 **
Pct_Img       0.28287    0.05113    5.532 5.12e-08 ***
Pct_brevet  -0.24004    0.03721   -6.451 2.63e-10 ***
NivVieMed    -0.31625    0.10180   -3.107 0.00200 **

---Significance stars
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
Residual standard error: 6.685 on 500 degrees of freedom
Multiple R-squared:  0.2832
Adjusted R-squared:  0.276
F-statistic: 39.5 on 5 and 500 DF,  p-value: < 2.2e-16
***Extra Diagnostic information
Residual sum of squares: 22346.02
Sigma(hat): 6.658629
AIC: 3366.626
AICc: 3366.851
BIC: 2933.798
*****
*           Results of Geographically Weighted Regression           *
*****

*****Model calibration information*****
Kernel function: bisquare
Adaptive bandwidth: 97 (number of nearest neighbours)
Regression points: the same locations as observations are used.
Distance metric: A distance matrix is specified for this model calibration.

*****Summary of GWR coefficient estimates:*****
            Min.   1st Qu.   Median   3rd Qu.   Max.
Intercept 13.249694 30.566393 38.903053 48.035033 59.6124
Pct0_14   -1.094930 -0.371546 -0.224906 -0.053956  0.3386
Pct_65    -0.711775 -0.157939 -0.033630  0.073991  0.4514
Pct_Img    -0.319353 -0.042105  0.078841  0.243274  0.6657
Pct_brevet -0.624419 -0.224105 -0.092008  0.041021  0.5844
NivVieMed -1.108017 -0.555822 -0.213561  0.202347  1.2844
*****Diagnostic information*****
Number of data points: 506
Effective number of parameters (2trace(S) - trace(S'S)): 103.4065

```

```

Effective degrees of freedom (n-2trace(S) + trace(S'S)): 402.5935
AICc (GWR book, Fotheringham, et al. 2002, p. 61, eq 2.33): 2949.788
AIC (GWR book, Fotheringham, et al. 2002,GWR p. 96, eq. 4.22): 2839.039
BIC (GWR book, Fotheringham, et al. 2002,GWR p. 61, eq. 2.34): 2743.804
Residual sum of squares: 6933.276
R-square value: 0.7775915
Adjusted R-square value: 0.7203234
*****F test results of GWR calibration*****
---F1 test (Leung et al. 2000)
  F1 statistic Numerator DF Denominator DF      Pr(>)
      0.38534          Inf           500 < 2.2e-16 ***
---F2 test (Leung et al. 2000)
  F2 statistic Numerator DF Denominator DF Pr(>)
      3.5405      -31.0892           500    NaN
---F3 test (Leung et al. 2000)
      F3 statistic Numerator DF Denominator DF      Pr(>)
Intercept      2.3480      133.2095          Inf < 2.2e-16 ***
Pct0_14         2.8529      141.2525          Inf < 2.2e-16 ***
Pct_65          2.1479      168.6132          Inf 3.399e-16 ***
Pct_Img         1.9938      105.6136          Inf 5.756e-09 ***
Pct_brevet      2.4930      120.8152          Inf < 2.2e-16 ***
NivVieMed       3.8747      138.4279          Inf < 2.2e-16 ***
---F4 test (GWR book p92)
  F4 statistic Numerator DF Denominator DF      Pr(>)
      0.31027      402.59351           500 < 2.2e-16 ***

---Significance stars
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
*****
Program stops at: 2025-01-24 01:05:52.934946

```

4.2.2.3 Cartographie des résultats du modèle GWR

Une fois le modèle obtenu, nous disposons de l'ensemble des résultats locaux (coefficients, valeur prédite, résidus, valeurs de t et R^2) dans l'objet `Modele.GWR$SDF` qui sera une couche `sf` comme le jeu de données initial. Il est ainsi aisée de reproduire les cartes présentées à la section 4.2.1.4. En guise d'exemple, dans le code ci-dessous, nous cartographions les valeurs locales du R^2 et uniquement celles de t pour la variable relative au médiane du niveau de vie (figure 4.10).

```

GWR.Resultats <- Modele.GWR$SDF
names(GWR.Resultats)

```

```

[1] "Intercept"      "Pct0_14"        "Pct_65"         "Pct_Img"
[5] "Pct_brevet"     "NivVieMed"      "y"              "yhat"
[9] "residual"       "CV_Score"       "Stud_residual"  "Intercept_SE"
[13] "Pct0_14_SE"     "Pct_65_SE"      "Pct_Img_SE"     "Pct_brevet_SE"

```

```
[17] "NivVieMed_SE" "Intercept_TV" "Pct0_14_TV" "Pct_65_TV"
[21] "Pct_Img_TV" "Pct_brevet_TV" "NivVieMed_TV" "Local_R2"
[25] "geometry"
```

```
legende.parametres <- list(text.separator = "à",
                           text.less.than = "Moins de",
                           text.or.more = "et plus",
                           decimal.mark = ",",
                           big.mark = " ")

classes.intervalles = c(-Inf, -3.29, -2.58, -1.96, 1.96, 2.58, 3.29, Inf)

# Cartographie du R2
Carte1 <- tm_shape(GWR.Resultats)+
  tm_borders(col="gray25", lwd=.5)+
  tm_fill(col="Local_R2",
          palette="YlOrBr",
          n=5, style="quantile",
          legend.format = legende.parametres,
          title = "R2 locaux")+
  tm_layout(frame=FALSE)+
  tm_scale_bar(breaks=c(0,5))

# Cartographie d'une valeur de t
Carte2 <- tm_shape(GWR.Resultats)+ tm_borders(col="gray25", lwd=.5)+
  tm_fill(col="NivVieMed_TV", palette="-RdBu",
          midpoint = NA,
          breaks = classes.intervalles,
          legend.format = legende.parametres,
          title = "Niveau de vie (€1000))+
  tm_layout(frame=FALSE)

tmap_arrange(Carte1, Carte2)
```




Figure 4.10: Exemple de cartographie avec les résultats de la GWR obtenus avec le *package GWmodel*

4.3 GWR classiques pour d'autres distributions

Aller plus loin

Modèles GWR avec d'autres distributions

Dans ce chapitre, nous avons décrit la GWR classique avec une distribution gaussienne qui est une extension de la régression linéaire multiple. Pour construire ce type de GWR classique, nous avons utilisé les fonctions `gwr.sel` et `gwr` du *package* `spgwr`. De la même manière, il est possible de construire des modèles GWR qui sont des extensions des modèles linéaires généralisés (GLM), notamment pour des variables dépendantes qualitatives (modèle logistique binomial), de comptage (Poisson, quasi-poisson), continues (gaussien, inverse gaussienne, Gamma). Pour ce faire, il faut utiliser les fonctions `bw.ggwr` et `ggwr` du *package* `spgwr` et spécifier le type de distribution avec l'argument `family` dont la valeur par défaut est `gaussian()`. Cet argument permet de spécifier la famille de distribution et la fonction de lien en utilisant les familles de distribution disponibles dans la fonction de `glm` (*Generalized Linear Models* pour régressions linéaires généralisées) :

- `binomial(link = "logit")`
- `gaussian(link = "identity")`
- `Gamma(link = "inverse")`
- `inverse.gaussian(link = "1/mu^2")`
- `poisson(link = "log")`
- `quasi(link = "identity", variance = "constant")`
- `quasibinomial(link = "logit")`
- `quasipoisson(link = "log")`

Avec le *package* `GWmodel`, vous pourrez utiliser les fonctions `bw.ggwr` et `gwss` qui permettent de réaliser des régressions linéaires pondérées avec des distributions de Poisson et binomiale (avec l'argument `family = "poisson"` et `family = "binomial"`)

4.4 Limites et critiques des GWR

Bien que la GWR classique représente un outil d'exploration de données spatiales particulièrement intéressant pour évaluer l'importance de l'instabilité spatiale d'un modèle de régression (Apparicio, Séguin et Leloup 2007; Mennis et Jordan 2005; Calvo et Escolar 2003), elle comprend plusieurs limites :

- **Type de distance.** Dans le cadre de ce chapitre, nous avons calculé la GWR avec la distance euclidienne qui n'est pas adapté à tous les phénomènes à l'étude. Par exemple, Lu, Charlton et Fotheringham (2011) utilisent des distances calculées sur un réseau de rues pour modéliser le prix de vente des maisons à Londres avec un modèle GWR. Pour ce faire, il est possible d'utiliser les fonctions `bw.gwr` et `gwr.basic` du *package* `GWmodel` dont l'argument `dmat` permet de spécifier une matrice de distance prédéfinie.
- **Choix du noyau (kernel) et la taille de la zone d'influence** peuvent impacter grandement les résultats. En effet, la zone d'influence (défini avec une distance ou un nombre donné de plus proches voisins) peut entraîner localement un nombre insuffisant d'observations, compromettant ainsi la robustesse des équations de régression locales.

- **Prédicteurs locaux et globaux.** Nous avons vu que la fonction `LMZ.F3GWR.test` permet de déterminer si les coefficients de régression présentent des variations significatives dans l'espace. Or, certaines variables indépendantes peuvent être introduites globalement et non localement, comme nous le verrons dans le prochain chapitre (section 5.1).

La GWR fait face aussi à d'importantes critiques :

- **Validité des modèles locaux.** Pour une régression linéaire multiple, il est primordial de réaliser un diagnostic pour s'assurer du nombre suffisant d'observations, de l'absence de multicollinéarité excessive et de la normalité et l'homoscédasticité des résidus (lire par exemple la [section suivante](#) (Apparicio et Gelb 2022)). Or, ce diagnostic devrait être réalisé pour tous les modèles locaux obtenus pour les n observations du jeu de données. Par exemple, si le modèle global ne pose pas de problème de multicollinéarité excessive, rien ne garantit qu'elle ne soit pas présente dans plusieurs modèles locaux (Wheeler et Tiefelsdorf 2005).
- **Corrélation entre les coefficients locaux.** Dans un article intitulé *Multicollinearity and correlation among local regression coefficients in geographically weighted regression*, Wheeler et Tiefelsdorf (2005) signalent les coefficients de régression locaux peuvent être fortement corrélés entre eux, en raison d'un problème de multicollinéarité excessive des modèles locaux. En guise d'exemple, la figure 4.11 montre bien que certaines paires de coefficients locaux sont corrélées fortement.

```
library("GGally")
df <- data.frame(Modele.GWR$SDF)
df <- df[, 2:7]
names(df) <- c("Constante" , "Pct0_14", "Pct_65", "Pct_Img", "Pct_brevet", "NivVieMed")

# Graphique avec le package GGally
ggpairs(df, progress = FALSE)
# Il est aussi possible de réaliser un graphique avec le package corrplot
library("corrplot")
# p <- cor(df, method="pearson")
# couleurs <- colorRampPalette(c("#053061", "#2166AC" , "#4393C3", "#92C5DE",
#                               "#D1E5F0", "#FFFFFF", "#FDDBC7", "#F4A582",
#                               "#D6604D", "#B2182B", "#67001F"))
# corrplot.mixed(p, lower="number", lower.col = "black",
#               upper = "ellipse", upper.col=couleurs(100))
```




Figure 4.11: Corrélation de Pearson entre les coefficients de régression locaux de la GWR

4.5 Quiz de révision

4.6 Exercices de révision

Exercice

Exercice 1. Réalisation d'un GWR classique

```
library(sf)
library(spgwr)
load("data/Lyon.Rdata")
# Ajout des coordonnées x et y
xy <- à compléter
LyonIris$X <- à compléter
LyonIris$Y <- à compléter
# Optimisation du nombre de voisins avec le CV
formule <- "PM25 ~ Pct0_14+Pct_65+Pct_Img+Pct_brevet+NivVieMed"
bwCV.voisins <- gwr.sel(à compléter)
# Réalisation de la GWR
Modele.GWR <- gwr(à compléter)
# Affichage des résultats
Modele.GWR
```

Correction à la section 8.4.1.

Exercice

Exercice 2. Comparaison des modèles MCO et GWR

```
library(sf)
library(spgwr)
# Modèle MCO
Modele.Global <- à compléter
# Comparaison des R2
R2.global <- à compléter
rss <- à compléter
tss <- à compléter
R2.GWRquasiglobal <- à compléter
cat("R2 global (LM) = ", round(R2.global, 3),
    "\nR2 quasi-global (GWR) : ", round(R2.GWRquasiglobal, 3))
# Comparaison des R2
à compléter
# Les coefficients du modèle GWR varient-ils significativement dans l'espace?
à compléter
```

Correction à la section 8.4.2.

 Exercice**Exercice 3.** Cartographie des R^2 et des valeurs de t

```
library(tmap)
# Récupération du R carré locaux et valeurs de t locales
à compléter

## Cartographie des R2 locaux
à compléter

# Cartographie des valeurs de t locales
## Paramètres pour la légende
legende.parametres <- list(text.separator = "à",
                           text.less.than = "Moins de",
                           text.or.more = "et plus",
                           decimal.mark = ",",
                           big.mark = " ")

## Cartographie
à compléter
```

Correction à la section 8.4.3.

5 Extensions de la régression géographiquement pondérée

Dans le chapitre 4, nous avons présenté les trois formes classiques de la régression géographiquement pondérée (GWR) qui permettent de modéliser des variables dépendantes continues (GWR gaussienne), dichotomiques (GWR logistique) ou des variables de comptage (GWR Poisson). Depuis la publication de l'ouvrage de référence de Steward Fotheringham, Chris Brunsdon et Martin Charlton (2003), plusieurs extensions ont vu le jour. Parmi celles-ci, nous abordons dans ce chapitre :

- la GWR mixte qui permet de spécifier des variables indépendantes variant spatialement et d'autres étant fixes (Fotheringham, Brunsdon et Charlton 2003).
- La régression géographiquement pondérée multiéchelle (*Multiscale Geographically Weighted Regression* – MGWR) (Fotheringham, Yang et Kang 2017).
- Les GWR mixtes intégrant des variables spatialement décalées (MGWR-SAR) (Geniaux et Martinetti 2018).

Objectif

Objectifs d'apprentissage visés dans ce chapitre

À la fin de ce chapitre, vous devriez être en mesure de :

- Comprendre pourquoi utiliser différentes extensions de la GWR (GWR-mixte, MGWR, GTWR et MGWR-SAR).
- Assimiler les principes fondamentaux de ces différentes extensions de la GWR.
- Appréhender les différentes extensions de la GWR (GWR-mixte, MGWR, GTWR et MGWR-SAR).
- Analyser les résultats produits par ces différentes extensions.
- Mettre en pratique ces extensions de la GWR dans R.

Package

Liste des *packages* utilisés dans ce chapitre

- Pour importer et manipuler des fichiers géographiques :
 - `sf` pour importer et manipuler des données vectorielles.
 - `dplyr` pour manipuler les données.
- Pour construire des cartes et des graphiques :
 - `tmap` pour les cartes.
 - `ggplot2` pour construire des graphiques.
- Pour construire différentes extensions de la GWR :
 - `Gwmodel` pour construire des GWR mixtes, des MGWR et des GTWR.
 - `mgwrsar` pour construire des GWR avec des variables spatialement décalées.

5.1 Régression géographiquement pondérée mixte

5.1.1 Principe de base de la GWR mixte

5.1.1.1 Pourquoi recourir à une GWR mixte

5.1.1.2 Formulation de la GWR mixte

5.1.2 Mise en oeuvre de la GWR mixte dans R

5.2 Régression géographiquement pondérée multiéchelle

5.2.1 Principe de base de la MGWR

5.2.1.1 Pourquoi recourir à une GWR mixte

5.2.1.2 Formulation de la GWR mixte

5.2.2 Mise en oeuvre de la MGWR dans R

5.3 Régression géographiquement pondérée mixte avec des variables spatialement décalée

5.3.1 Principe de base de la MGWR-SAR

5.3.1.1 Pourquoi recourir à une MGWR-SAR

5.3.1.2 Formulation de la MGWR-SAR

5.3.2 Mise en oeuvre de la MGWR-SAR dans R

5.4 Quiz de révision

5.5 Exercices de révision

Exercice

Exercice 1. Réalisation d'un GWR classique

```
library(sf)
library(spgwr)
```

Correction à la ?@sec-06041.

Exercice

Exercice 2. Réalisation d'un GWR classique mixte

```
library(sf)
library(spgwr)
```

Correction à la ?@sec-06042.

Exercice

Exercice 3. Réalisation d'un GWR classique multiéchelle

```
library(sf)
library(spgwr)
```

Correction à la ?@sec-06043.

Partie 4. Autres approches de modélisations spatiales

6 Modèles généralisées additifs

Dans ce chapitre, nous abordons deux formes de modèles généralisées additifs (*Generalized additive model* en anglais – GAM) qui permettent d’introduire l’espace deux manières différentes : les modèles GAM avec une *spline* bivariée avec les coordonnées géographiques (x, y) pour capturer les variations continues dans l’espace; les modèles GAM avec un lissage par champ aléatoire de Markov (*random markov field* – RMF) pour modéliser la dépendance spatiale entre les unités spatiales voisines.

🎯 Objectif

Objectifs d’apprentissage visés dans ce chapitre

À la fin de ce chapitre, vous devriez être en mesure de :

- Comprendre pourquoi utiliser un modèle GAM avec un *spline* bivariée sur les coordonnées géographiques ou avec un lissage par champ aléatoire de Markov.
- Comprendre les différences entre ces deux modèles : effets spatiaux lisses et globaux *versus* effets spatiaux locaux avec dépendance de voisinage.
- Analyser les résultats produits par ces deux types de modèles GAM.
- Les mettre en pratique dans R.

📦 Package

Liste des *packages* utilisés dans ce chapitre

- Pour importer et manipuler des fichiers géographiques :
 - `sf` pour importer et manipuler des données vectorielles.
- Pour construire des cartes et des graphiques :
 - `tmap` est certainement le meilleur *package* pour la cartographie.
 - `ggplot2` pour construire des graphiques.
- Pour construire des modèles GAM :
 - `mgcv` pour pratiquer ses GAM dans R!

6.1 Modèles généralisés additifs (GAM) avec une *spline* bivariée sur les coordonnées géographiques

Les modèles généralisés additifs (*Generalized additive models* en anglais) permettent d’intégrer à la fois des effets linéaires et des effets non linéaires avec des *splines*. Ils peuvent alors être utilisés en intégrant une *spline* bivariée sur les

coordonnées géographiques des centroïdes des entités spatiales.

⚠ Attention

Modèles généralisés additifs

Pour une description détaillée des modèles généralisés additifs, nous vous invitons vivement à lire le [chapitre suivant](#) (Apparicio et Gelb 2024).

6.1.1 Principe de base d'un GAM intégrant l'espace

6.1.1.1 Formulation d'un modèle GAM vec une spline bivariable sur les coordonnées géographiques

Avec une *spline* bivariable sur les coordonnées géographiques, l'équation d'un modèle généralisé additif s'écrit :

$$g(Y) = \beta_0 + X\beta + s(\text{Coord}X, \text{Coord}Y) + \epsilon \quad (6.1)$$

avec :

- y , la variable dépendante.
- β_0 , la constante.
- X , les variables indépendantes.
- β , les coefficients des variables dépendantes.
- $s(\text{Coord}X, \text{Coord}Y)$, *spline* bivariable sur les coordonnées x et y .
- ϵ , les résidus.

6.1.1.2 Pourquoi recourir à un modèle GAM avec une spline bivariable sur les coordonnées géographiques

L'intérêt de recourir à une *spline* bivariable sur les coordonnées géographiques est double :

1. Contrôler l'effet de la localisation sur la variable dépendante (y). Les coefficients des autres variables indépendantes sont ainsi obtenus une fois l'espace pris en compte.
2. Évaluer l'effet de la localisation (patron spatial), une fois les autres variables indépendantes contrôlées. Autrement dit, toutes choses étant égales par ailleurs, quel est l'effet de la localisation sur la variable dépendante?

6.1.2 Mise en oeuvre et analyse dans R

6.1.2.1 Réalisation du modèle GAM

Pour construire des modèles GAM dans R, nous utilisons la fonction `gam` du *package* `mgcv` (Wood 2011).

```
## Chargement des packages et des données
library(sf)
library(spdep)
library(mgcv)
load("data/Lyon.Rdata")
## Ajout des coordonnées X et Y dans LyonIris
xy <- st_coordinates(st_centroid(LyonIris))
LyonIris$X <- xy[,1]
LyonIris$Y <- xy[,2]
## Construction du modèle MCO
Modele.MCO <- lm(N02 ~ Pct0_14+Pct_65+Pct_Img+Pct_brevet+NivVieMed,
                 data = LyonIris)
## Construction du modèle GAM
Modele.GAM1 <- gam(N02 ~ Pct0_14+Pct_65+Pct_Img+Pct_brevet+NivVieMed+
                   s(X, Y), # spline sur les coordonnées X, Y
                   family=gaussian(), # distribution
                   data = LyonIris) # dataframe
## Résultats du modèle
summary(Modele.GAM1)
```

Family: gaussian

Link function: identity

Formula:

N02 ~ Pct0_14 + Pct_65 + Pct_Img + Pct_brevet + NivVieMed + s(X,
Y)

Parametric coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	30.402313	2.156322	14.099	<2e-16 ***
Pct0_14	-0.053641	0.046224	-1.160	0.246
Pct_65	-0.056310	0.038476	-1.463	0.144
Pct_Img	0.008033	0.035397	0.227	0.821
Pct_brevet	0.043874	0.027518	1.594	0.112
NivVieMed	-0.043282	0.072461	-0.597	0.551

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Approximate significance of smooth terms:

	edf	Ref.df	F	p-value
s(X,Y)	26.5	28.62	27.22	<2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

R-sq.(adj) = 0.715 Deviance explained = 73.3%

GCV = 18.814 Scale est. = 17.605 n = 506

Les résultats ci-dessus signalent que la localisation a un effet très significatif puisque $s(X,Y) = 26,5$ avec $p < 0,001$. Notez que la valeur de p permet de déterminer si la *spline* bivariée (et donc l'espace) a ou non un effet significatif. Si la valeur de p est supérieure à 0,05, alors il n'est pas nécessaire de conserver la *spline* bivariée sur les coordonnées géographiques.

De plus, le code ci-dessous permet de constater que le modèle GAM est plus performant que le modèle linéaire multiple classique (MCO).

```
anova(Modele.MCO, Modele.GAM1)
```

Analysis of Variance Table

Model 1: NO2 ~ Pct0_14 + Pct_65 + Pct_Img + Pct_brevet + NivVieMed

Model 2: NO2 ~ Pct0_14 + Pct_65 + Pct_Img + Pct_brevet + NivVieMed + s(X,
Y)

	Res.Df	RSS	Df	Sum of Sq	F	Pr(>F)
1	500.0	22346.0				
2	473.5	8336.1	26.5	14010	30.029	< 2.2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Nous pouvons aussi introduire une *spline* plus complexe en augmentant le nombre de nœuds à 40.

```
Modele.GAM2 <- gam(NO2 ~ Pct0_14+Pct_65+Pct_Img+Pct_brevet+NivVieMed+
                      s(X, Y, k= 40),
                      family=gaussian(),
                      data = LyonIris)
summary(Modele.GAM2)
```

Family: gaussian

Link function: identity

Formula:

NO2 ~ Pct0_14 + Pct_65 + Pct_Img + Pct_brevet + NivVieMed + s(X,
Y, k = 40)

Parametric coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	30.372093	2.088160	14.545	<2e-16 ***
Pct0_14	-0.055294	0.044285	-1.249	0.2124
Pct_65	-0.049122	0.036870	-1.332	0.1834
Pct_Img	0.002226	0.033722	0.066	0.9474
Pct_brevet	0.052229	0.026315	1.985	0.0478 *

```

NivVieMed    -0.050991    0.070081   -0.728    0.4672
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Approximate significance of smooth terms:
      edf Ref.df      F p-value
s(X,Y) 35.68  38.51 24.27  <2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

R-sq.(adj) =  0.747   Deviance explained = 76.7%
GCV = 17.014   Scale est. = 15.613      n = 506

```

La valeur plus faible d'AIC pour le second modèle GAM signale qu'il est plus performant que le premier.

```
AIC(Modele.MCO, Modele.GAM1, Modele.GAM2)
```

```

      df      AIC
Modele.MCO  7.00000 3366.626
Modele.GAM1 33.50046 2920.682
Modele.GAM2 42.67520 2868.355


```

6.1.2.2 Visualisation de l'effet de l'espace

Pour visualiser les prédictions du modèle dans l'espace, toutes choses étant égales par ailleurs, nous utilisons la fonction `vis.gam` (figure 6.1). Les contours signalent qu'au centre de Lyon, les valeurs de dioxyde d'azote sont les plus élevées et dépassent même $40 \mu\text{g}/\text{m}^3$.

```
vis.gam(Modele.GAM2, view=c("X", "Y"), plot.type = "contour", color="terrain")
```

linear predictor

Figure 6.1: Visualisation des prédictions dans l'espace avec la fonction `vis.gam`

Toutefois, il est plus intéressant de la représenter dans un *raster*, une fois contrôlées les autres variables indépendantes. Pour ce faire, six étapes sont nécessaires :

1. Créer une *grid*.
2. Fixer les autres paramètres à leur moyenne respective.
3. Calculer la prédiction pour la localisation.
4. Centrer la prédiction.
5. Construire le *raster* avec les prédictions.
6. Découper et cartographier le *raster*.

```
library(raster)
library(terra)
## Étape 1 : création d'une grid pour la prédiction de 100 mètres de résolution spatiale
Xcoords <- seq(min(LyonIris$X-100), max(LyonIris$X+100), by=100)
Ycoords <- seq(min(LyonIris$Y-100), max(LyonIris$Y+100), by=100)
PredDF <- expand.grid(Xcoords,Ycoords)
names(PredDF) <- c("X","Y")
## Étape 2 : fixation de tous les autres paramètres à leur moyenne
for(Var in c("VegHautPrt","Pct0_14","Pct_65","Pct_Img","Pct_brevet", "NivVieMed")){
  PredDF[[Var]] <- mean(LyonIris[[Var]])
}
## Étape 3 : calcul de la prédiction
PredDF$PM25 <- predict(Modele.GAM2,newdata=PredDF)
## Étape 4 : centrage de la prédiction (sans la constante)
```

```
PredDF$CenterPredPM25 <- PredDF$PM25 - mean(PredDF$PM25)
### Étape 5 : construction du raster
rasterGAM <- rasterFromXYZ(PredDF[, c("X", "Y", "CenterPredPM25")])
crs(rasterGAM) <- crs(as(LyonIris, "Spatial"))
rasterGAM <- rast(rasterGAM)
### Étape 6 : découpage et cartographie du raster
LyonIris.SpatVector <- vect(LyonIris)
rasterGAM <- terra::mask(rasterGAM, LyonIris.SpatVector)
terra::plot(rasterGAM)
```




Figure 6.2: Visualisation de l'effet de la localisation centrée sur zéro

La figure 6.2 signale que dans le centre de Lyon, le dioxyde d'azote est plus élevé de 10 à 20 $\mu\text{g}/\text{m}^3$, toutes choses étant égales par ailleurs. À l'inverse, dans les zones périphériques, il est faible. Cela signale un net patron spatial décroissant du centre vers la périphérie.

6.1.2.3 Dépendance spatiale du modèle GAM

Par contre, bien que l'autocorrélation spatiale des résidus du modèle GAM soit plus faible que pour le modèle MCO (I de Moran de 0,337 contre 0,570 avec $p < 0,001$), il reste que le problème de la dépendance spatiale n'est pas corrigé.

```
## Matrice de contiguïté selon le partage d'un segment (Rook)
Rook <- poly2nb(LyonIris, queen=FALSE)
W.Rook <- nb2listw(Rook, zero.policy=TRUE, style = "W")
## Autocorrélation sur les résidus du modèle GAM
moran.mc(resid(Modele.GAM2), W.Rook, nsim=999)
```

Monte-Carlo simulation of Moran I

```
data: resid(Modele.GAM2)
weights: W.Rook
number of simulations + 1: 1000
```

```
statistic = 0.33664, observed rank = 1000, p-value = 0.001
alternative hypothesis: greater
```

6.2 GAM avec un lissage par champ aléatoire de Markov

6.2.1 Principe de base d'un avec un champ aléatoire de Markov

6.2.2 Mise en oeuvre et analyse dans R

<https://fromthebottomoftheheap.net/2017/10/19/first-steps-with-mrf-smooths/>

 Aller plus loin**Modèles généralisées additifs avec d'autres distributions pour la variable dépendante**

Dans ce chapitre, nous avons créé des modèles GAM en introduisant l'espace de deux manières différentes, et ce, avec une distribution gaussienne. Or, il est aussi possible de construire ces deux types de modèles avec des variables dépendantes qualitatives (modèles logistique, probit, multinomial, ordinal), de comptage (modèles Poisson, binomial négatif, avec excès fixe de zéros, avec excès ajusté de zéros), continues (gaussien, Student, Gamma, bêta).

La fonction `gam` du *package* `mgcv` comprend un argument `family` dont la valeur par défaut est `gaussian()`. Cet argument permet de spécifier la famille de distribution et la fonction de lien en utilisant les familles de distribution disponibles dans la fonction de `glm` (*Generalized Linear Models* pour régressions linéaires généralisées) :

- `binomial(link = "logit")`
- `gaussian(link = "identity")`
- `Gamma(link = "inverse")`
- `inverse.gaussian(link = "1/mu^2")`
- `poisson(link = "log")`
- `quasi(link = "identity", variance = "constant")`
- `quasibinomial(link = "logit")`
- `quasipoisson(link = "log")`

D'autres familles de distribution sont aussi spécifiques la fonction `gam` de `mgcv` :

- `betar(link="logit")`
- `cnorm(theta=NULL, link="identity")`
- `nb(theta = NULL, link = "log")`
- `ocat(theta=NULL, link="identity", R=NULL)`
- `scat(theta = NULL, link = "identity", min.df=3)`
- `tw(theta = NULL, link = "log", a=1.01, b=1.99)`
- `zip(theta = NULL, link = "identity", b=0)`

6.3 Quiz de révision

6.4 Exercices de révision

Exercice

Exercice 1. Réalisation d'un modèle GAM

```
library(sf)
library(mgcv)
load("data/chap07/DonneesLyon.Rdata")
# Ajout des coordonnées x et y
xy <- à compléter
LyonIris$X <- à compléter
LyonIris$Y <- à compléter
# Construction du modèle
formule <- "PM25 ~ Pct0_14+Pct_65+Pct_Img+Pct_brevet+NivVieMed"
Modele.GAM2 <- gam(NO2 ~ à compléter
                    à compléter,
                    data = LyonIris)
summary(Modele.GAM2)
```

Correction à la ?@sec-12072.

7 Modèles avec des vecteurs propres spatiaux

Dans ce chapitre, nous abordons les modèles linéaires généralisés avec des vecteurs spatiaux proposés par Daniel Griffith (2003; Griffith, Chun et Li 2019).

Objectif

Objectifs d'apprentissage visés dans ce chapitre

À la fin de ce chapitre, vous devriez être en mesure de :

- À compléter.
- À compléter.
- Analyser les résultats produits par ce type de modèle.
- Les mettre en pratique dans R.

Package

Liste des *packages* utilisés dans ce chapitre

- Pour importer et manipuler des fichiers géographiques :
 - `sf` pour importer et manipuler des données vectorielles.
- Pour construire des cartes et des graphiques :
 - `tmap` est certainement le meilleur *package* pour la cartographie.
 - `ggplot2` pour construire des graphiques.
- Pour construire des modèles GAM :
 - `spfilter` est un package dédié à ce type de modèles.

Partie 7. Exercices et bibliographie

8 Correction des exercices

8.1 Exercices du chapitre 1

8.1.1 Exercice 1

8.1.2 Exercice 2

8.1.3 Exercice 3

8.2 Exercices du chapitre 2

8.2.1 Exercice 1

8.2.2 Exercice 2

8.2.3 Exercice 3

8.3 Exercices du chapitre 3

8.3.1 Exercice 1

8.3.2 Exercice 2

8.3.3 Exercice 3

8.4 Exercices du chapitre 4

8.4.1 Exercice 1

```
library(sf)
library(spgwr)
load("data/Lyon.Rdata")
# Ajout des coordonnées x et y
xy <- st_coordinates(st_centroid(LyonIris))
LyonIris$X <- xy[,1]
LyonIris$Y <- xy[,2]
```

```

# Optimisation du nombre de voisins avec le CV
formule <- "PM25 ~ Pct0_14+Pct_65+Pct_Img+Pct_brevet+NivVieMed"
bwaCV.voisins <- gwr.sel(formule,
                        data = LyonIris,
                        method = "cv",
                        gweight=gwr.bisquare,
                        adapt=TRUE,
                        verbose = FALSE,
                        RMSE = TRUE,
                        longlat = FALSE,
                        coords=cbind(LyonIris$X,LyonIris$Y))

# Optimisation du nombre de voisins avec l'AIC
formule <- "PM25 ~ Pct0_14+Pct_65+Pct_Img+Pct_brevet+NivVieMed"
bwaCV.voisins <- gwr.sel(formule,
                        data = LyonIris,
                        method = "CV",
                        gweight=gwr.bisquare,
                        adapt=TRUE,
                        verbose = FALSE,
                        RMSE = TRUE,
                        longlat = FALSE,
                        coords=cbind(LyonIris$X,LyonIris$Y))

# Réalisation de la GWR
Modele.GWR <- gwr(formule,
                  data = LyonIris,
                  adapt=bwaCV.voisins,
                  gweight=gwr.bisquare,
                  hatmatrix=TRUE,
                  se.fit=TRUE,
                  coords=cbind(LyonIris$X,LyonIris$Y),
                  longlat=FALSE)

# Affichage des résultats
Modele.GWR

```

8.4.2 Exercice 2

```

# Modèle MCO
Modele.Global <- lm(formule, data = LyonIris)
# Comparaison des R2
R2.global <- summary(Modele.Global)$r.squared
rss <- sum((Modele.GWR$lm$y - Modele.GWR$SDF$pred)^2)
tss <- sum((Modele.GWR$lm$y - mean(Modele.GWR$SDF$pred))^2)
R2.GWRquasiglobal <- 1 - (rss / tss)
cat("R2 global (LM) = ", round(R2.global, 3),

```

```

  "\nR2 quasi-global (GWR) : ", round(R2.GWRquasiglobal, 3))
# Comparaison des R2
anova(Modele.GWR)
LMZ.F1GWR.test(Modele.GWR)
LMZ.F2GWR.test(Modele.GWR)
# Les coefficients du modèle GWR varient-ils significativement dans l'espace?
LMZ.F3GWR.test(Modele.GWR)

```

8.4.3 Exercice 3

```

library(tmap)
# Récupération du R carré locaux et valeurs de t locales
LyonIris$GWR.R2 <- Modele.GWR$SDF$localR2
VarsIndep <- c("Pct0_14", "Pct_65", "Pct_Img", "Pct_brevet", "NivVieMed")
for(e in VarsIndep){
  # Nom des nouvelles variables
  var.coef <- paste0("GWR.", "B_", e)
  var.t <- paste0("GWR.", "T_", e)
  # Récupération des coefficients pour les variables indépendantes
  LyonIris[[var.coef]] <- Modele.GWR$SDF[[e]]
  # Calcul des valeurs de t pour les variables indépendantes
  LyonIris[[var.t]] <- Modele.GWR$SDF[[e]] / Modele.GWR$SDF[[paste0(e, "_se")]]
}

# Cartographie des R2 locaux
legendes.parametres <- list(text.separator = "à",
                             decimal.mark = ",",
                             big.mark = " ")

tm_shape(LyonIris)+
  tm_borders(col="gray25", lwd=.5)+
  tm_fill(col="GWR.R2",
          palette="YlOrBr",
          n=5, style="quantile",
          legend.format = legendes.parametres,
          title = "R2 locaux")+
  tm_layout(frame=FALSE)+
  tm_scale_bar(breaks=c(0,5))

# Cartographie des valeurs de t locales
## Paramètres pour la légende
legende.parametres <- list(text.separator = "à",
                           text.less.than = "Moins de",
                           text.or.more = "et plus",
                           decimal.mark = ",",

```

```

        big.mark = " ")

## Cartographie
classes.intervalles = c(-Inf, -3.29, -2.58, -1.96, 1.96, 2.58, 3.29, Inf)
Carte1 <- tm_shape(LyonIris)+ tm_borders(col="gray25", lwd=.5)+
  tm_fill(col="GWR.T_Pct0_14", palette="-RdBu",
    midpoint = NA,
    breaks = classes.intervalles,
    legend.format = legende.parametres,
    title = "Moins de 15 ans (%)")+
  tm_layout(frame=FALSE, legend.outside = TRUE)

Carte2 <- tm_shape(LyonIris)+ tm_borders(col="gray25", lwd=.5)+
  tm_fill(col="GWR.T_Pct_65", palette="-RdBu",
    midpoint = NA,
    breaks = classes.intervalles,
    legend.format = legende.parametres,
    title = "65 ans et plus (%)")+
  tm_layout(frame=FALSE, legend.outside = TRUE)

Carte3 <- tm_shape(LyonIris)+ tm_borders(col="gray25", lwd=.5)+
  tm_fill(col="GWR.T_Pct_Img", palette="-RdBu",
    midpoint = NA,
    breaks = classes.intervalles,
    legend.format = legende.parametres,
    title = "Immigrants (%)")+
  tm_layout(frame=FALSE, legend.outside = TRUE)

Carte4 <- tm_shape(LyonIris)+ tm_borders(col="gray25", lwd=.5)+
  tm_fill(col="GWR.B_Pct_brevet", palette="-RdBu",
    midpoint = NA,
    breaks = classes.intervalles,
    legend.format = legende.parametres,
    title = "Faible scolarité (%)")+
  tm_layout(frame=FALSE, legend.outside = TRUE)

Carte5 <- tm_shape(LyonIris)+ tm_borders(col="gray25", lwd=.5)+
  tm_fill(col="GWR.T_NivVieMed", palette="-RdBu",
    midpoint = NA,
    breaks = classes.intervalles,
    legend.format = legende.parametres,
    title = "Niveau de vie (€1000)")+
  tm_layout(frame=FALSE, legend.outside = TRUE)+
  tm_scale_bar(breaks=c(0,5))

tmap_arrange(Carte1, Carte2, Carte3, Carte4, Carte5, ncol = 2, nrow=3)

```

8.5 Exercices du chapitre 5

8.5.1 Exercice 1

8.5.2 Exercice 2

8.5.3 Exercice 3

Bibliographie

- Anselin, Luc. 1988. *Spatial econometrics: methods and models*. Kluwer Academic Publishers.
- . 2010. « Thirty years of spatial econometrics. » *Papers in regional science* 89 (1): 3-26. <https://doi.org/10.1111/j.1435-5957.2010.00279.x>.
- Anselin, Luc, Anil K Bera, Raymond Florax et Mann J Yoon. 1996. « Simple diagnostic tests for spatial dependence. » *Regional science and urban economics* 26 (1): 77-104. [https://doi.org/10.1016/0166-0462\(95\)02111-6](https://doi.org/10.1016/0166-0462(95)02111-6).
- Apparicio, Philippe et Jérémy Gelb. 2022. *Méthodes quantitatives en sciences sociales : un grand bol d'R*. FabriqueREL, Licence CC BY-SA. <https://serieboldr.github.io/MethodesQuantitatives/>.
- . 2024. *Méthodes d'analyse spatiales : un grand bol d'R*. FabriqueREL, Licence CC BY-SA. <https://serieboldr.github.io/MethodesAnalyseSpatiale/>.
- Apparicio, Philippe, Anne-Marie Séguin et Xavier Leloup. 2007. « Modélisation spatiale de la pauvreté à Montréal: apport méthodologique de la régression géographiquement pondérée. » *The Canadian Geographer/Le Géographe canadien* 51 (4): 412-427. <https://doi.org/10.1111/j.1541-0064.2007.00189.x>.
- Binbin Lu, Paul Harris, Martin Charlton et Christopher Brunsdon. 2014. « The GWmodel R package: further topics for exploring spatial heterogeneity using geographically weighted models. » *Geo-spatial Information Science* 17 (2): 85-101. [10.1080/10095020.2014.917453](https://doi.org/10.1080/10095020.2014.917453).
- Bivand, Roger, Giovanni Millo et Gianfranco Piras. 2021. « A review of software for spatial econometrics in R. » *Mathematics* 9 (11): 1276. <https://doi.org/10.3390/math9111276>.
- Bivand, Roger et Danlin Yu. 2023. *spgwr: Geographically Weighted Regression*. s.n. <https://CRAN.R-project.org/package=spgwr>.
- Brunsdon, Chris, A Stewart Fotheringham et Martin Charlton. 1998. « Spatial nonstationarity and autoregressive models. » *Environment and Planning A* 30 (6). SAGE Publications Sage UK: London, England: 957-973.
- Brunsdon, Chris, A Stewart Fotheringham et Martin E Charlton. 1996. « Geographically weighted regression: a method for exploring spatial nonstationarity. » *Geographical analysis* 28 (4). Wiley Online Library: 281-298.
- Calvo, Ernesto et Marcelo Escolar. 2003. « The local voter: A geographically weighted approach to ecological inference. » *American Journal of Political Science* 47 (1): 189-204. <https://doi.org/10.1111/1540-5907.00013>.
- Dubé, Jean et Diègo Legros. 2014. *Econométrie spatiale appliquée des microdonnées*. ISTE Group.
- Fotheringham, A Stewart, Chris Brunsdon et Martin Charlton. 2003. *Geographically weighted regression: the analysis of spatially varying relationships*. John Wiley & Sons.
- Fotheringham, A Stewart, Wenbai Yang et Wei Kang. 2017. « Multiscale geographically weighted regression (MGWR). » *Annals of the American Association of Geographers* 107 (6). Taylor & Francis: 1247-1265. <https://doi.org/10.1080/24694452.2017.1352480>.
- Geary, Robert C. 1954. « The contiguity ratio and statistical mapping. » *The incorporated statistician* 5 (3): 115-146. <https://doi.org/10.2307/2986645>.
- Geniaux, Ghislain et Davide Martinetti. 2018. « A new method for dealing simultaneously with spatial autocorrelation and spatial heterogeneity in regression models. » *Regional Science and Urban Economics* 72: 74-85. <https://doi.org/10.1016/j.regsciurbeco.2017.04.001>.
- Griffith, Daniel A. 1988. *Advanced Spatial Statistics: Special Topics in the Exploration of Quantitative Spatial Data Series*. Kluwer Academic Publishers.

- . 2003. *Spatial autocorrelation and spatial filtering: gaining understanding through theory and scientific visualization*. Springer.
- Griffith, Daniel A., Yongwan Chun et Bin Li. 2019. *Spatial regression analysis using eigenvector spatial filtering*. Academic Press.
- Isabella Gollini, Binbin Lu, Martin Charlton, Christopher Brunsdon et Paul Harris. 2015. « GWmodel: An R Package for Exploring Spatial Heterogeneity Using Geographically Weighted Models. » *Journal of Statistical Software* 63 (17): 1-50. [10.18637/jss.v063.i17](https://doi.org/10.18637/jss.v063.i17).
- Lu, Binbin, Martin Charlton et A Stewart Fotheringham. 2011. « Geographically weighted regression using a non-Euclidean distance metric with a study on London house price data. » *Procedia Environmental Sciences* 7: 92-97. <https://doi.org/10.1016/j.proenv.2011.07.017>.
- Mantel, Nathan. 1967. « The detection of disease clustering and a generalized regression approach. » *Cancer research* 27 (2_Part_1): 209-220.
- Mennis, Jeremy L et Lisa Jordan. 2005. « The distribution of environmental equity: Exploring spatial nonstationarity in multivariate models of air toxic releases. » *Annals of the Association of American Geographers* 95 (2): 249-268. <https://doi.org/10.1111/j.1467-8306.2005.00459.x>.
- Moran, Patrick. 1948. « The interpretation of statistical maps. » *Journal of the Royal Statistical Society. Series B (Methodological)* 10 (2): 243-251. <https://www.jstor.org/stable/2983777>.
- . 1950. « A test for the serial independence of residuals. » *Biometrika* 37 (1/2): 178-181. <https://doi.org/10.2307/2332162>.
- Paelinck, Jean. 1978. « Spatial econometrics. » *Economics Letters* 1 (1): 59-63. [https://doi.org/10.1016/0165-1765\(78\)90097-6](https://doi.org/10.1016/0165-1765(78)90097-6).
- Stewart Fotheringham, A, Martin Charlton et Chris Brunsdon. 1996. « The geography of parameter space: an investigation of spatial non-stationarity. » *International journal of geographical information systems* 10 (5). Taylor & Francis: 605-627.
- Tobler, Waldo R. 1970. « A computer movie simulating urban growth in the Detroit region. » *Economic geography* 46 (sup1): 234-240. <https://doi.org/10.2307/143141>.
- Wheeler, David et Michael Tiefelsdorf. 2005. « Multicollinearity and correlation among local regression coefficients in geographically weighted regression. » *Journal of Geographical Systems* 7 (2): 161-187. <https://doi.org/10.1007/s10109-005-0155-6>.
- Wood, Simon N. 2011. « Fast stable restricted maximum likelihood and marginal likelihood estimation of semiparametric generalized linear models. » *Journal of the Royal Statistical Society Series B: Statistical Methodology* 73 (1): 3-36. <https://doi.org/10.1111/j.1467-9868.2010.00749.x>.